دانشگاه صنعتی شریف
دانشکده مهندسی برق

مقدمه ای بر یادگیری ماشین

پروژه - طبقه بندی

نیلوفر محمودی

۴۰۲۱۰۲۳۹۲

استاد درس:

محمد باقر شمس الهی

نیمسال دوم ۱۴۰۴—۱۴۰۵

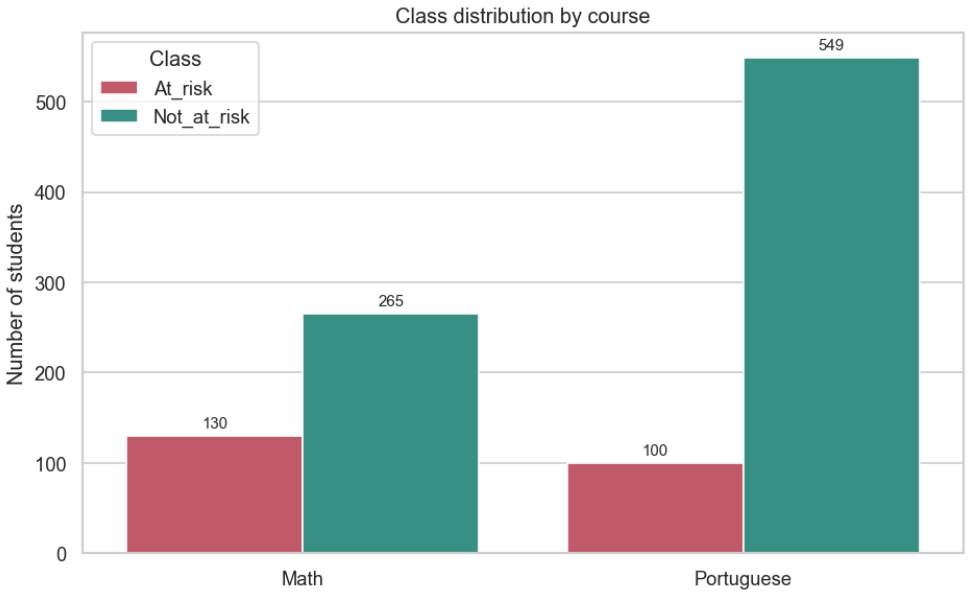
$$\text{Risk} = \begin{cases} 1 & G3 < 10, \\ 0 & G3 \geq 10. \end{cases} \tag{۱}$$

جدول ۱: تعریف سناریوهای زمانی

سناریو	زمان تصمیم	G1	G2
T0	ابتدای ترم	ندارد	ندارد
T1	پس از ارزیابی اول	دارد	ندارد
T2	پس از ارزیابی دوم	دارد	دارد

جدول ۲: مشخصات داده و توزیع

Course	Rows	Columns	At_risk	Not_at_risk	Risk_rate
Math	395	33	130	265	0.329
Portuguese	649	33	100	549	0.154



برای هر درس، داده ها با $RandomSeed = 392$ به سه بخش آموزش، اعتبارسنجی و آزمون با نسبت های 60%، 20% و 20% تقسیم شدند. استانداردسازی ویژگی های عددی و کدگذاری One-Hot ویژگی های دسته ای داخل pipeline انجام شد تا اطلاعات مجموعه آزمون وارد پیش پردازش آموزش نشود. تنظیمات هر مدل با عملکرد مجموعه اعتبارسنجی و به ترتیب اولویت F1 و Balanced accuracy انتخاب شد. سپس مدل منتخب با داده آموزش و اعتبارسنجی دوباره آموزش دید و تنها یک بار روی آزمون ارزیابی شد.

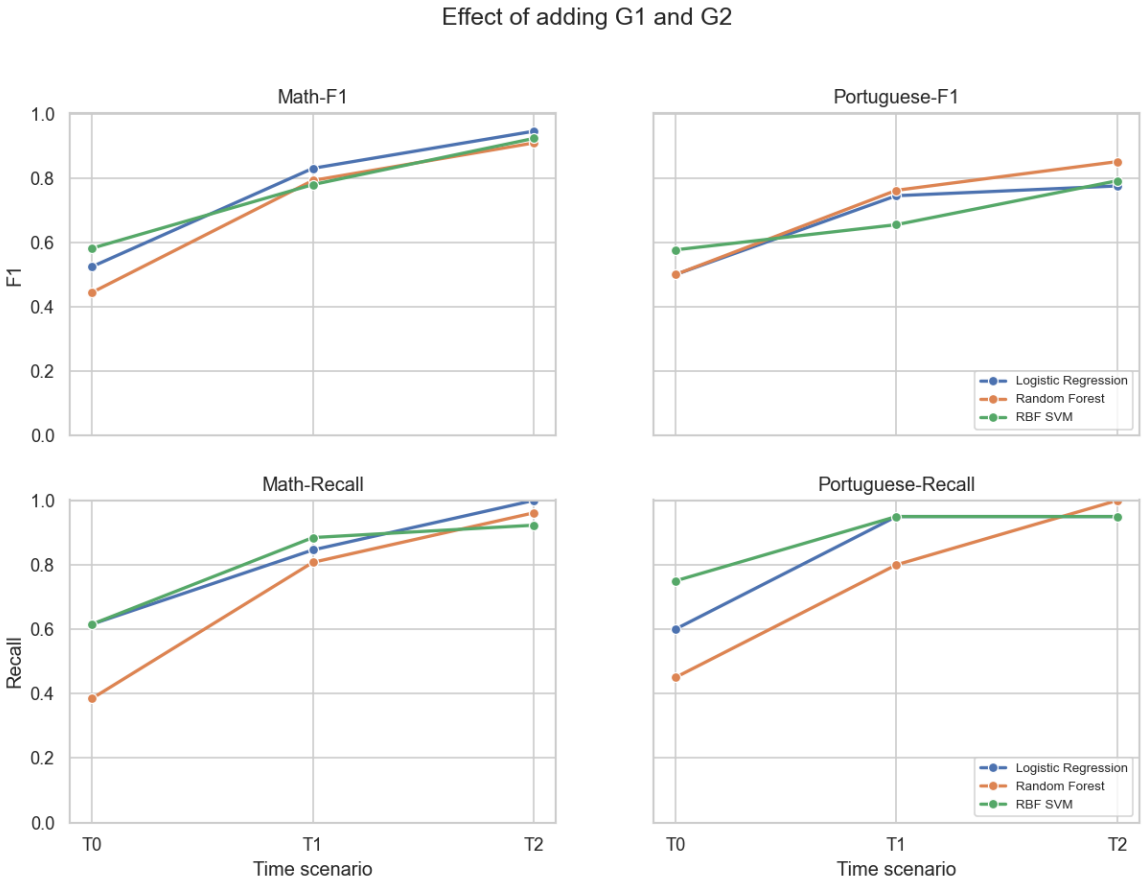
سه مدل انتخاب شدند: Logistic Regression ، Random Forest ، RBF SVM

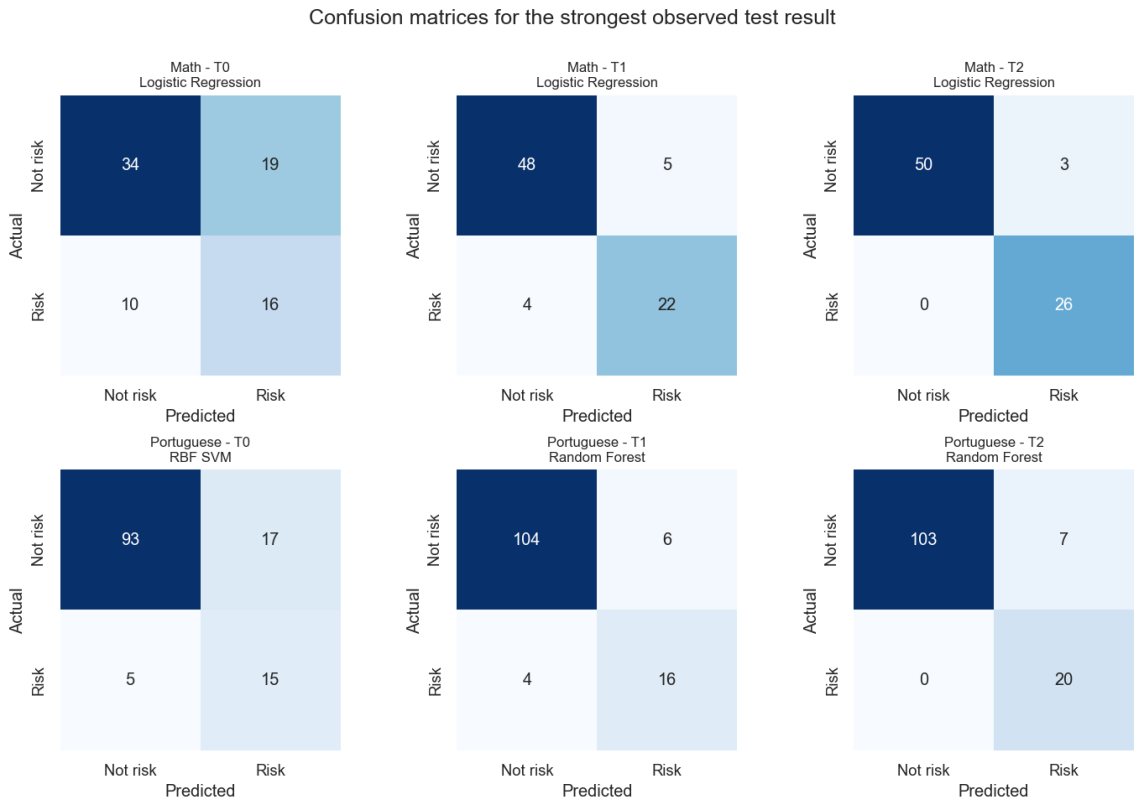
۱ پرسش اول

در هر درس و هر سناریوی زمانی، سه مدل آموزش داده شد. برای Logistic Regression پارامتر $C \in \{0.1, 1, 10\}$، برای Random Forest عمق درخت و حداقل اندازه برگ، و برای RBF SVM پارامترهای C و γ روی مجموعه اعتبارسنجی بررسی شدند. جدول زیر عملکرد آزمون تمام مدل ها را گزارش می کند. مدل های بولد شده بهترین مدل هایی هستند که بر اساس اعتبارسنجی انتخاب شده اند.

جدول ۳: عملکرد تمام مدل ها روی مجموعه آزمون

Course	Scenario	Model	Accuracy	Balanced Accuracy	Precision	Recall	F1	PR-AUC
math	T0	**LR**	0.633	0.628	0.457	0.615	0.525	0.618
	T0	RF	0.684	0.607	0.526	0.385	0.444	0.565
	T0	RBF-SVM	0.709	0.685	0.552	0.615	0.582	0.583
	T1	**LR**	0.886	0.876	0.815	0.846	0.830	0.908
	T1	RF	0.861	0.847	0.778	0.808	0.792	0.938
	T1	RBF-SVM	0.835	0.848	0.697	0.885	0.780	0.925
	T2	**LR**	0.962	0.972	0.897	1.000	0.945	0.984
	T2	RF	0.937	0.943	0.862	0.962	0.909	0.971
	T2	RBF-SVM	0.949	0.943	0.923	0.923	0.923	0.983
Portuguese	T0	LR	0.815	0.727	0.429	0.600	0.500	0.479
	T0	RF	0.862	0.693	0.562	0.450	0.500	0.566
	T0	**RBF-SVM**	0.831	0.798	0.469	0.750	0.577	0.583
	T1	LR	0.900	0.920	0.613	0.950	0.745	0.849
	T1	**RF**	0.923	0.873	0.727	0.800	0.762	0.877
	T1	RBF-SVM	0.846	0.889	0.500	0.950	0.655	0.889
	T2	LR	0.915	0.930	0.655	0.950	0.776	0.892
	T2	**RF**	0.946	0.968	0.741	1.000	0.851	0.965
	T2	RBF-SVM	0.923	0.934	0.679	0.950	0.792	0.924





در ابتدای ترم، اطلاعات Categorical مقداری قدرت تفکیک دارند اما پیش بینی هنوز متوسط است. مدل منتخب ریاضی در T0 به F1 برابر 0.525 و Recall 0.615 رسیده است. در پرتغالی، RBF-SVM با F1 برابر 0.577 و Recall

0.75 بهتر عمل کرده است. هرچند RBF-SVM ریاضی روی آزمون F1 برابر 0.582 دارد، انتخاب نهایی آن مجاز نیست، زیرا Logistic Regression روی اعتبارسنجی رتبه بالاتری گرفته بود.

اضافه شدن G1 جهش بزرگی ایجاد می کند: F1 مدل منتخب ریاضی از 0.525 به 0.83 و پرتغالی از 0.577 به 0.762 می رسد. در T2 این مقادیر به 0.945 و 0.851 افزایش می یابند و Recall هر دو درس برابر 1 می شود. نتیجه اصلی این است که شناسایی دانش آموزان پرریسک ممکن است اما کیفیت تصمیم به زمان آن وابسته است. T0 برای سنجش اولیه مفید است، T1 تعادل مناسبی میان زودهنگام بودن و دقت دارد و T2 دقیق ترین ولی دیرترین هشدار را ارائه می کند.

۲ پرسش دوم

برای نشان دادن اثر عدم توازن، یک مدل base line با مدل منتخب هر سناریو مقایسه شد. جدول زیر نشان می دهد که این مدل می تواند دقت ظاهرا مناسب داشته باشد در حالی که هیچ دانش آموز پرریسکی را شناسایی نمی کند.

جدول ۴: مقایسه خط مبنای با مدل های منتخب

PR-AUC	F1	Recall	Balanced Accuracy	Accuracy	Scenario	Type	Course
0.329	0.000	0.000	0.500	0.671	—	Base Line	Math
0.618	0.525	0.615	0.628	0.633	T0	Model	Math
0.908	0.830	0.846	0.876	0.886	T1	Model	Math
0.984	0.945	1.000	0.972	0.962	T2	Model	Math
0.154	0.000	0.000	0.500	0.846	—	Base Line	Portuguese
0.583	0.577	0.750	0.798	0.831	T0	Model	Portuguese
0.877	0.762	0.800	0.873	0.923	T1	Model	Portuguese
0.965	0.851	1.000	0.968	0.946	T2	Model	Portuguese

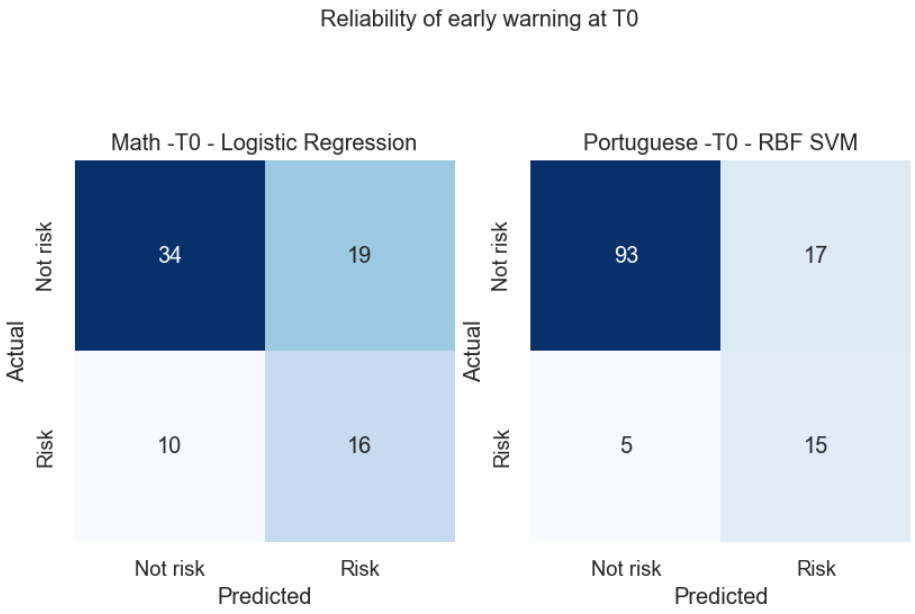
مثال مربوط به T0 پرتغالی یک مثال واضح است. Base Line دقت 0.846 دارد در حالی که دقت مدل واقعی کمی کمتر و برابر 0.831 است. با این حال خط مبنا از 20 دانش آموز پرریسک موجود در آزمون هیچ موردی را پیدا نمی کند؛ ولی مدل 15 نفر را شناسایی می کند. پس دقت به تنهایی گمراه کننده است.برای راه حل می توانیم همزمان Confusion matrices، Recall، F1 Precision، Balanced Accuracy و PR-AUC و همچنین تنظیم آستانه بر اساس هزینه خطاها است.

۳ پرسش سوم

برای سنجش عدم قطعیت، روی پیش بینی های آزمون T0 تعداد 2000 نمونه بوت استرپ انجام شد. فاصله اطمینان 95% چند معیار اصلی در جدول آمده است.

جدول ۵: برآورد بوت استرپ عملکرد T0

CI_97.5	CI_2.5	Estimate	Metric	Course
0.743	0.514	0.628	Balanced Accuracy	Math
0.793	0.417	0.615	Recall	Math
0.657	0.364	0.525	F1	Math
0.774	0.442	0.618	PR-AUC	Math
0.894	0.689	0.798	Balanced Accuracy	Portuguese
0.933	0.550	0.750	Recall	Portuguese
0.719	0.400	0.577	F1	Portuguese
0.763	0.374	0.583	PR-AUC	Portuguese



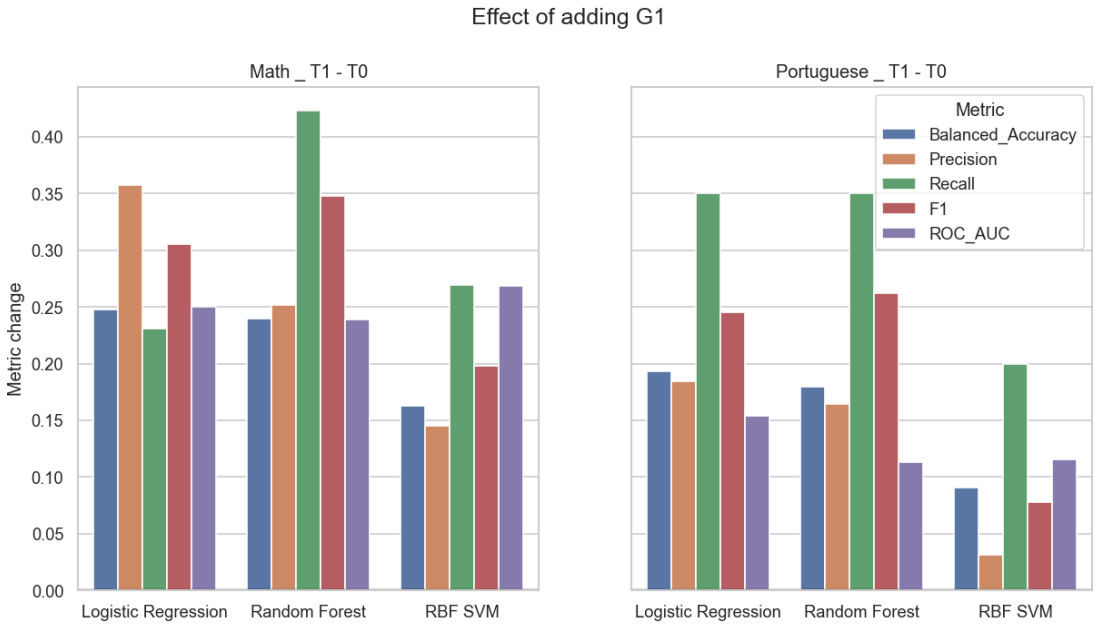
در ریاضی نرخ هشدار اشتباه 0.358 و نرخ از دست دادن دانش آموز پرریسک 0.385 است یعنی 19 هشدار اشتباه و 10 مورد از دست رفته وجود دارد. در پرتغالی این دو نرخ به ترتیب 0.155 و 0.25 هستند و 17 هشدار اشتباه و 5 مورد از دست رفته ثبت شده است. پهن بودن فاصله های اطمینان به ویژه برای Recall و F1 نشان می دهد که تعداد نمونه مثبت آزمون برای ادعای قطعیت بالا کافی نیست. بنابراین هشدار T0 برای سنجش اولیه قابل استفاده است اما نباید به تنهایی مبنای تصمیم قطعی آموزشی قرار گیرد.

۴ پرسش چهارم

برای جدا کردن اثر G1 اختلاف عملکرد بهترین مدل میان T1 و T0 محاسبه شد.

جدول ۶: تغییر معیارها پس از اضافه شدن G1

PR-AUC Change	F1 Change	Recall Change	Balanced Accuracy Change	Model	Course
+0.290	+0.306	+0.231	+0.247	LR	Math
+0.373	+0.348	+0.423	+0.240	RF	Math
+0.342	+0.198	+0.269	+0.163	RBF-SVM	Math
+0.370	+0.245	+0.350	+0.193	LR	Portuguese
+0.311	+0.262	+0.350	+0.180	RF	Portuguese
+0.306	+0.078	+0.200	+0.091	RBF-SVM	Portuguese



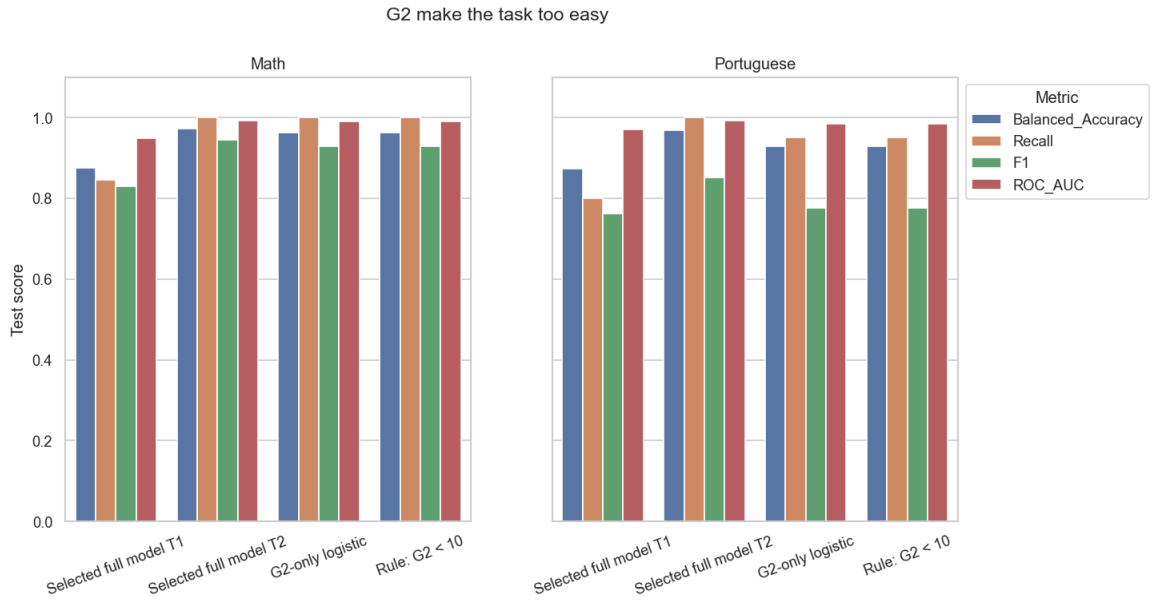
بهبود در هر شش ترکیب درس و مدل مثبت است و فقط به یک الگوریتم محدود نمی شود. برای مدل های منتخب F1 ریاضی 0.306 و پرتغالی 0.185 افزایش یافته است. همچنین تعداد FN ریاضی از 10 به 4 و پرتغالی از 5 به 4 کاهش یافته است. بنابراین G1 نشانه مستقیم و قوی از وضعیت تحصیلی است و سناریوی T1 نسبت به T0 معتبر و قابل استنادتر است.

۵ پرسش پنجم

همبستگی G2 و G3 در ریاضی 0.905 و در پرتغالی 0.919 است. همچنین برچسب حاصل از $G2 < 10$ با برچسب نهایی در ریاضی 0.919 و در پرتغالی 0.897 توافق دارد.

جدول ۷: مقایسه مدل کامل با مدل مبتنی بر G2

PR-AUC	F1	Recall	Balanced Accuracy	Type	Course
0.908	0.830	0.846	0.876	T1 Best Model	Math
0.984	0.945	1.000	0.972	T2 Best Model	Math
0.969	0.929	1.000	0.962	$G2 < 10$	Math
0.877	0.762	0.800	0.873	T1 Best Model	Portuguese
0.965	0.851	1.000	0.968	T2 Best Model	Portuguese
0.906	0.776	0.950	0.930	$G2 < 10$	Portuguese



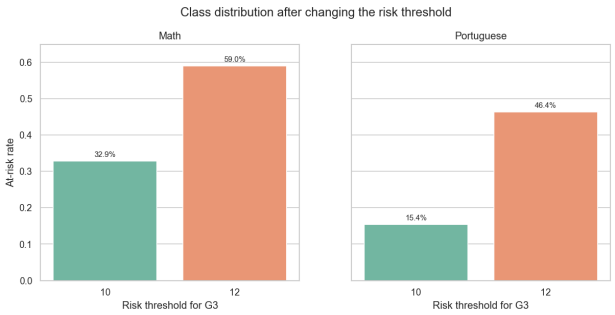
با اضافه شدن G2، F1 مدل منتخب ریاضی 0.115 و پرتغالی 0.089 افزایش یافته و FN هر دو درس به صفر رسیده است. از دید زمانی استفاده از G2 نشت داده نیست چون این نمره در سناریوی T2 واقعا پیش از G3 در دسترس است. با این حال مسئله بسیار ساده تر می شود چون G2 از نظر زمانی و آماری به G3 نزدیک است. مدل فقط با G2 تقریبا به مدل کامل می رسد. پس T2 برای هشدار دقیق مناسب است اما برای مداخله زودهنگام ارزش عملی کمتری از T1 دارد.

۶ پرسش ششم

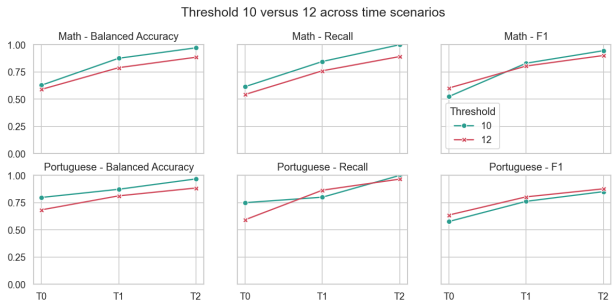
با تعریف جدید $G3 < 12$، نرخ کلاس مثبت در ریاضی از 0.329 به 0.59 و در پرتغالی از 0.154 به 0.464 افزایش یافت. برای مقایسه موقعیت نمونه های آموزش، اعتبارسنجی و آزمون، مدل و تنظیمات منتخب آستانه 10 ثابت نگه داشته شد و مدل با برچسب جدید دوباره آموزش دید.

جدول ۸: اثر تغییر تعریف ریسک بر عملکرد مدل منتخب

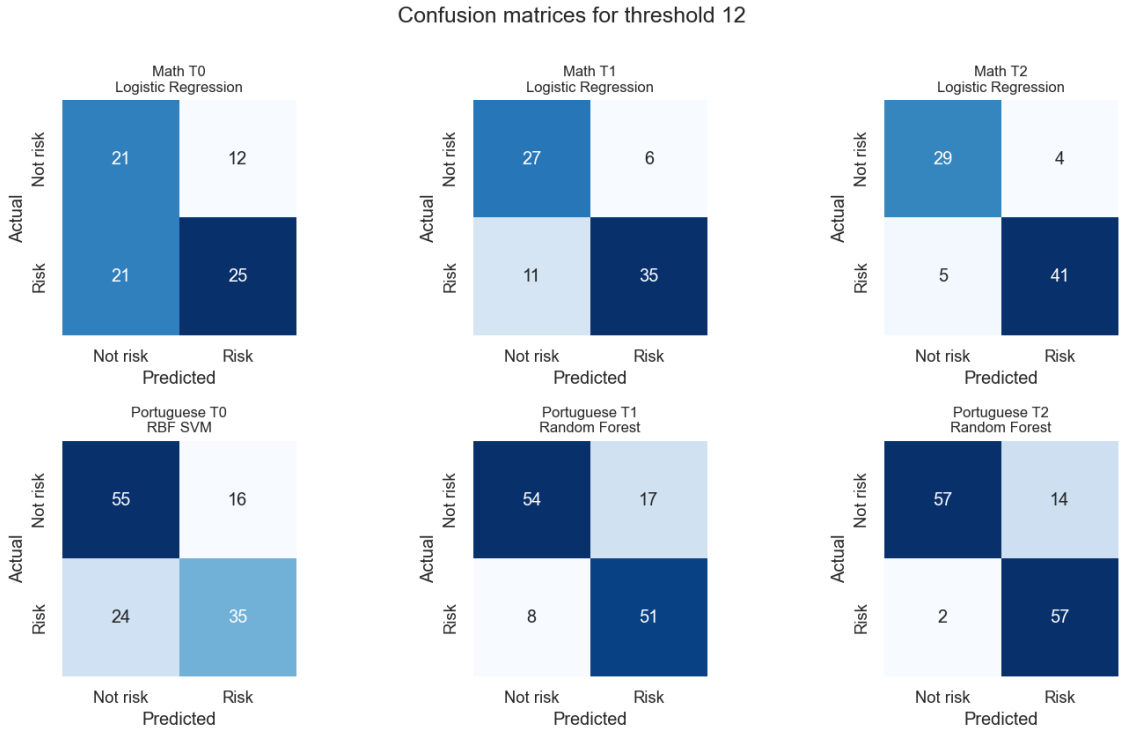
PR-AUC on 12	PR-AUC in 10	Recall in 12	Recall in 10	F1 in 12	F1 in 10	Scenario	Course
0.748	0.618	0.543	0.615	0.602	0.525	T0	Math
0.926	0.908	0.761	0.846	0.805	0.830	T1	Math
0.974	0.984	0.891	1.000	0.901	0.945	T2	Math
0.732	0.583	0.593	0.750	0.636	0.577	T0	Portuguese
0.878	0.877	0.864	0.800	0.803	0.762	T1	Portuguese
0.931	0.965	0.966	1.000	0.877	0.851	T2	Portuguese



(آ) تغییر توزیع کلاس



(ب) تغییر معیارها



افزایش آستانه کلاس مثبت را متوازن تر و ناهمگون تر می کند چون اکنون دانش آموزان مرزی با نمره 10 و 11 نیز پرریسک محسوب می شوند. در T0، F1 هر دو درس بهتر شده است که بخشی از آن به کاهش عدم توازن مربوط است. در ریاضی T1 و T2، F1 و Recall کاهش یافته اند زیرا تشخیص نمونه های مرزی دشوارتر است. در پرتغالی F1 افزایش یافته ولی Recall در T2 کاهش دارد. بنابراین تغییر آستانه صرفا مسئله را آسان یا سخت نمی کند. هم توزیع کلاس و هم مرز تصمیم را عوض می کند و مدل باید با برچسب جدید دوباره اعتبارسنجی شود.

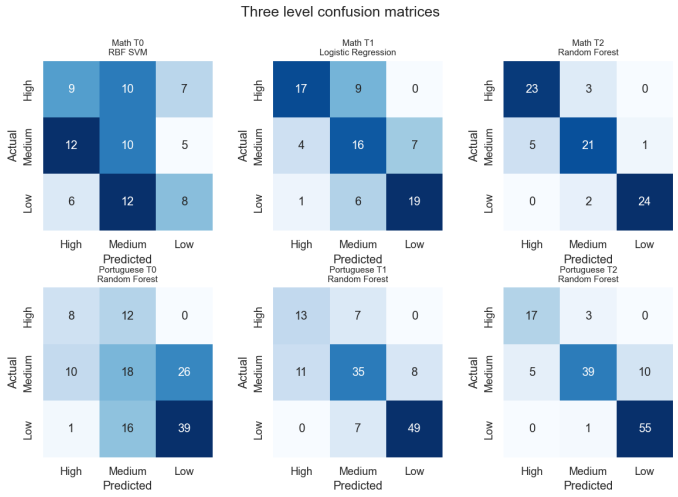
۷ پرسش هفتم

سه سطح به صورت ریسک بالا برای $G3 < 10$، ریسک متوسط برای $10 \leq G3 < 13$ و ریسک پایین برای $G3 \geq 13$ تعریف شد. در ریاضی هر سه سطح تقریبا متوازن هستند اما در پرتغالی سطح ریسک بالا فقط 0.154 داده ها را تشکیل می دهد.

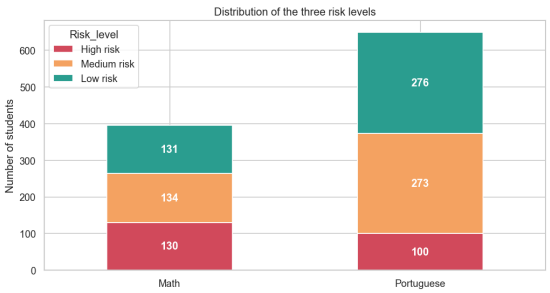
جدول ۹: عملکرد مدل منتخب در طبقه بندی سه سطحی

Macro-F1	Balanced Accuracy	Accuracy	Model	Scenario	Course
0.342	0.341	0.342	RBF-SVM	T0	Math
0.664	0.659	0.658	LR	T1	Math
0.862	0.862	0.861	RF	T2	Math
0.472	0.477	0.500	RF	T0	Portuguese
0.713	0.724	0.746	RF	T1	Portuguese
0.841	0.851	0.854	RF	T2	Portuguese

در T2، F1 کلاس های ریسک بالا، متوسط و پایین برای ریاضی به ترتیب 0.852، 0.792 و 0.941 و برای پرتغالی 0.810، 0.804 و 0.909 است. ضعیف ترین سطح در هر دو درس، سطح میانی است چون مرزهای 10 و 13 نمونه های نزدیک و مشابهی ایجاد می کنند.



(ب) ماتریس های درهم ریختگی



(آ) توزیع سه سطح

نتیجه این است که طبقه بندی سه سطحی امکان پذیر است، ولی در T0 قابل اتکا نیست و عملکرد ریاضی تقریبا در حد حدس سه کلاسه است. از T1 به بعد تفکیک معنادار می شود و در T2 کیفیت خوبی دارد. چون سطح ها دارای ترتیب

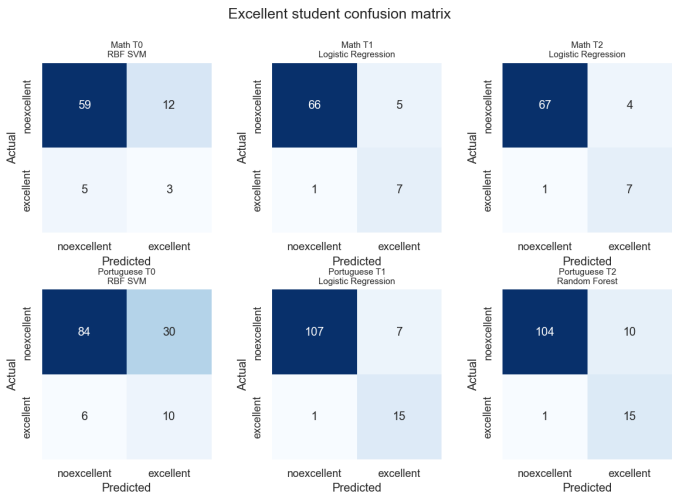
طبیعی هستند، در توسعه بعدی می توان طبقه بندی ترتیبی را نیز آزمود تا هزینه اشتباه میان دو سطح مجاور کمتر از اشتباه میان ریسک بالا و پایین در نظر گرفته شود.

۸ پرسش هشتم

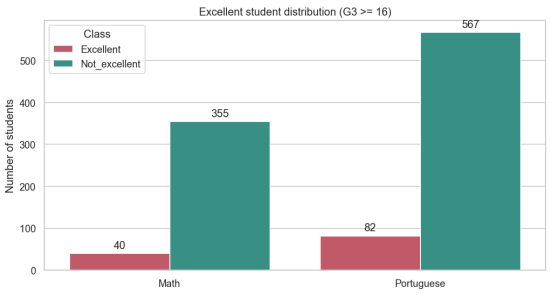
دانش آموز ممتاز با شرط $G3 \geq 16$ تعریف شد. فقط 40 نفر از 395 دانش آموز ریاضی و 82 نفر از 649 دانش آموز پرتغالی ممتاز هستند بنابراین این مسئله نیز نامتوازن است.

جدول ۱۰: عملکرد مدل منتخب برای شناسایی دانش آموزان ممتاز

PR-AUC	F1	Recall	Precision	Balanced Accuracy	Model	Scenario	Course
0.367	0.261	0.375	0.200	0.603	RBF-SVM	T0	Math
0.800	0.700	0.875	0.583	0.902	LR	T1	Math
0.842	0.737	0.875	0.636	0.909	LR	T2	Math
0.271	0.357	0.625	0.250	0.681	RBF-SVM	T0	Portuguese
0.931	0.789	0.938	0.682	0.938	LR	T1	Portuguese
0.787	0.732	0.938	0.600	0.925	RF	T2	Portuguese



(ب) ماتریس های درهم ریختگی



(آ) توزیع کلاس ممتاز

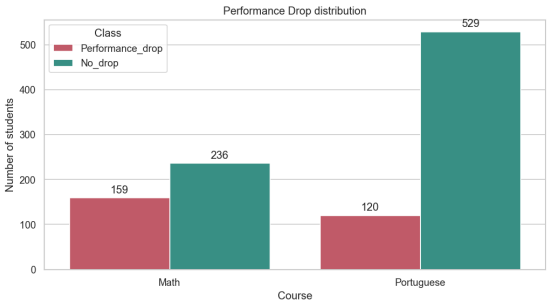
در T0، Precision بسیار پایین است یعنی FP ها بالا هستند. اضافه شدن G1 عملکرد را به شکل محسوسی بهبود می دهد. این تفاوت کوچک باید با احتیاط تفسیر شود چون در آزمون فقط 8 نمونه ممتاز ریاضی و 16 نمونه ممتاز پرتغالی وجود دارد. در نتیجه شناسایی ممتازها پس از G1 عملی است، اما نتیجه T0 برای تصمیم قطعی کافی نیست و ارزیابی تکرارشونده می تواند پایداری رتبه مدل ها را بهتر مشخص کند.

۹ پرسش نهم

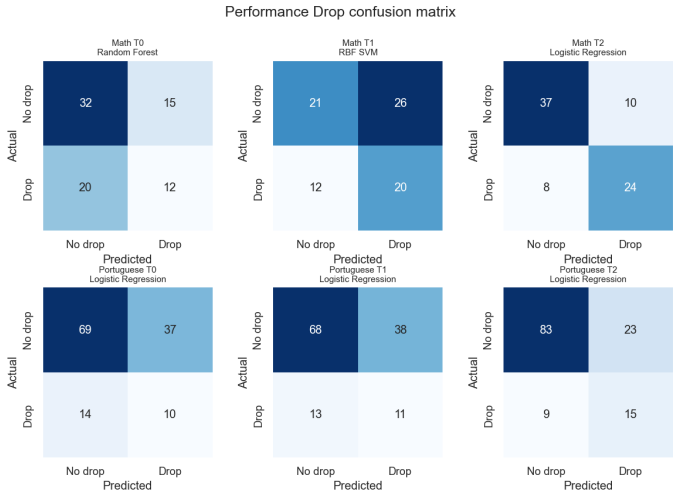
افت عملکرد با شرط $G3 < G1$ تعریف شد. نرخ افت در ریاضی 0.403 و در پرتغالی 0.185 است.

جدول ۱۱: عملکرد مدل منتخب برای پیش بینی افت عملکرد

PR-AUC	F1	Recall	Balanced Accuracy	Model	Scenario	Course
0.525	0.407	0.375	0.528	RF	T0	Math
0.487	0.513	0.625	0.536	RBF-SVM	T1	Math
0.777	0.727	0.750	0.769	LR	T2	Math
0.199	0.282	0.417	0.534	LR	T0	Portuguese
0.209	0.301	0.458	0.550	LR	T1	Portuguese
0.499	0.484	0.625	0.704	LR	T2	Portuguese



(آ) توزیع افت عملکرد



(ب) ماتریس های درهم ریختگی

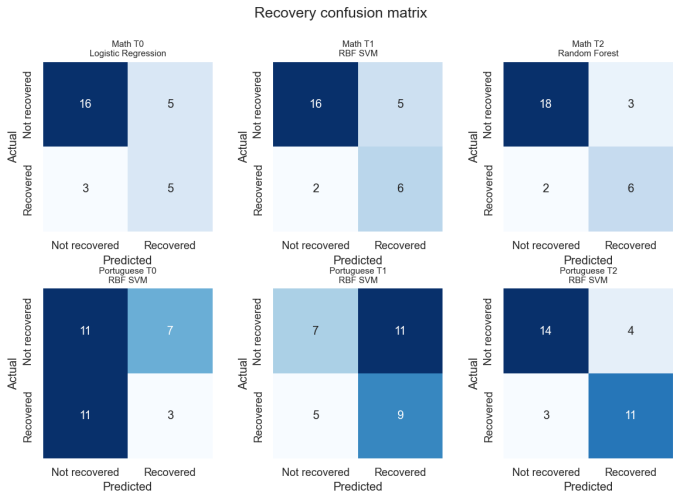
از نظر کاربردی T1 اولین زمان معتبر برای پیش بینی افت نسبت به G1 است. در این زمان عملکرد ریاضی متوسط و عملکرد پرتغالی ضعیف است. اضافه شدن G2 روند نمره را آشکار می کند و بهترین نتیجه را می دهد اما فاصله تا آزمون نهایی کمتر شده است. بنابراین افت عملکرد به ویژه در پرتغالی، از ویژگی های ثابت ابتدای ترم به خوبی قابل تشخیص نیست و به ویژگی های زمانی بیشتری مانند آزمون های میان دوره ای، تکلیف ها و روند حضور نیاز دارد.

۱۰ پرسش دهم

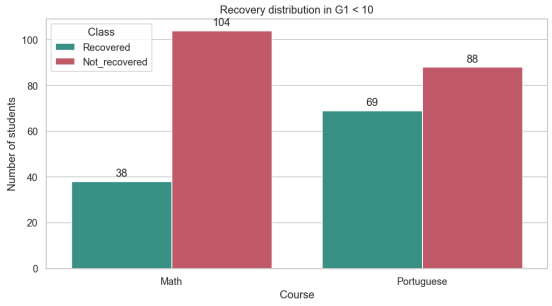
ابتدا دانش آموزان با $G1 < 10$ جدا شدند و سپس بازیابی با شرط $G3 \geq 10$ تعریف شد. در ریاضی 142 دانش آموز ضعیف وجود دارد که 38 نفر، یعنی نرخ 0.268، بازیابی شده اند. در پرتغالی از 157 دانش آموز ضعیف، 69 نفر با نرخ 0.439 بازیابی شده اند.

جدول ۱۲: عملکرد مدل منتخب برای پیش بینی بازیابی

PR-AUC	F1	Recall	Balanced Accuracy	Model	Scenario	Course
0.465	0.556	0.625	0.693	LR	T0	Math
0.641	0.632	0.750	0.756	RBF-SVM	T1	Math
0.736	0.706	0.750	0.804	RF	T2	Math
0.511	0.250	0.214	0.413	RBF-SVM	T0	Portuguese
0.459	0.529	0.643	0.516	RBF-SVM	T1	Portuguese
0.762	0.759	0.786	0.782	RBF-SVM	T2	Portuguese



(ب) ماتریس های درهم ریختگی



(آ) توزیع بازیابی

پیش بینی بازیابی در ریاضی از همان ابتدا اطلاعاتی فراتر از حد تصادف دارد ولی در پرتغالی T0 آنقدر قابل اعتماد نیست. در T1، خود G1 به دلیل شرط انتخاب $G1 < 10$ دامنه محدودی دارد و به تنهایی تفکیک قوی ایجاد نمی کند. G2 وضعیت بازیابی را بسیار روشن تر می سازد. پس پیش بینی اینکه دانش آموز ضعیف بتواند بعد از G1 شرایط خ.د را جبران کند قبل با اطلاعات T1 مسئله سخت تری است و نتایج فعلی برای تصمیم گیری منطقی کافی نیست.

۱۱ پرسش یازدهم

دانش آموزان مجموعه آزمون بر اساس احتمال پیش بینی شده ریسک، به صورت نزولی مرتب شدند. اگر ظرفیت برنامه برابر K نفر باشد، K دانش آموز نخست انتخاب می شوند. برای ارزیابی این تصمیم از Precision و Recall در K و ضریب بهبود نسبت به انتخاب تصادفی استفاده شد. جدول زیر نتایج ظرفیت مرجع 20% را نشان می دهد.

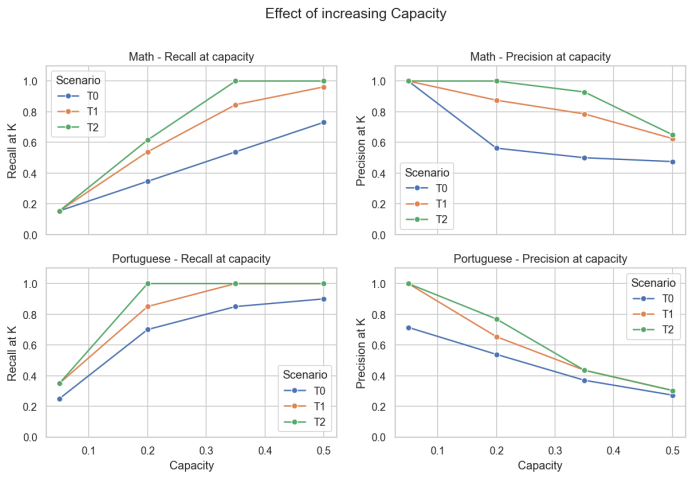
برای نمونه چهار اولویت نخست سناریوی عملی T1 در جدول زیر آمده است.

جدول ۱۳: چهار اولویت نخست برنامه در سناریوی T1

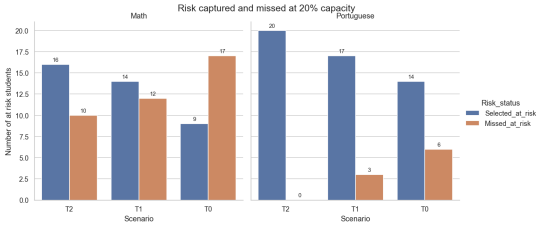
Risk probability	Student number	Risk rank	Course
0.999	387	1	Math
0.997	279	2	Math
0.996	371	3	Math
0.995	151	4	Math
0.819	501	1	Portuguese
0.743	633	2	Portuguese
0.739	588	3	Portuguese
0.712	611	4	Portuguese

جدول ۱۴: مقایسه سناریوها در ظرفیت 20%

Lift at K	Recall at K	Precision at K	Missed at risk	Selected at risk	Selected students	Scenario	Course
1.709	0.346	0.562	17	9	16	T0	Math
2.659	0.538	0.875	12	14	16	T1	Math
3.038	0.615	1.000	10	16	16	T2	Math
3.500	0.700	0.538	6	14	26	T0	Portuguese
4.250	0.850	0.654	3	17	26	T1	Portuguese
5.000	1.000	0.769	0	20	26	T2	Portuguese



(آ) تغییر دقت و فراخوانی با ظرفیت



(ب) ریسک پوشش داده شده در ظرفیت مرجع

با افزایش ظرفیت از 5% تا 50%، Recall افزایش و دقت در K کاهش می یابد. برای مثال در ریاضی T2، ظرفیت 35% تمام 26 دانش آموز پرریسک آزمون را پوشش می دهد، ولی افزایش بیشتر ظرفیت فقط افراد بدون ریسک را اضافه می کند. در پرتغالی T1 نیز ظرفیت 35% Recall 1 دارد.

از نظر آماری، T2 در هر دو درس بهترین رتبه بندی را ایجاد می کند. با این حال برای انتخاب عملی برنامه کمک آموزشی، T1 مناسب تر است چون پس از نخستین ارزیابی هنوز زمان کافی برای مداخله وجود دارد و عملکرد آن نیز بسیار بهتر از T0 است. اگر برنامه از نخستین روز ترم آغاز شود ناچار باید از T0 استفاده کرد و خطای بیشتر آن را پذیرفت. پس انتخاب سناریو فقط با عدد عملکرد انجام نمی شود و باید زمان باقی مانده برای اثرگذاری مداخله نیز در نظر گرفته شود.

۱۲ پرسش دوازدهم

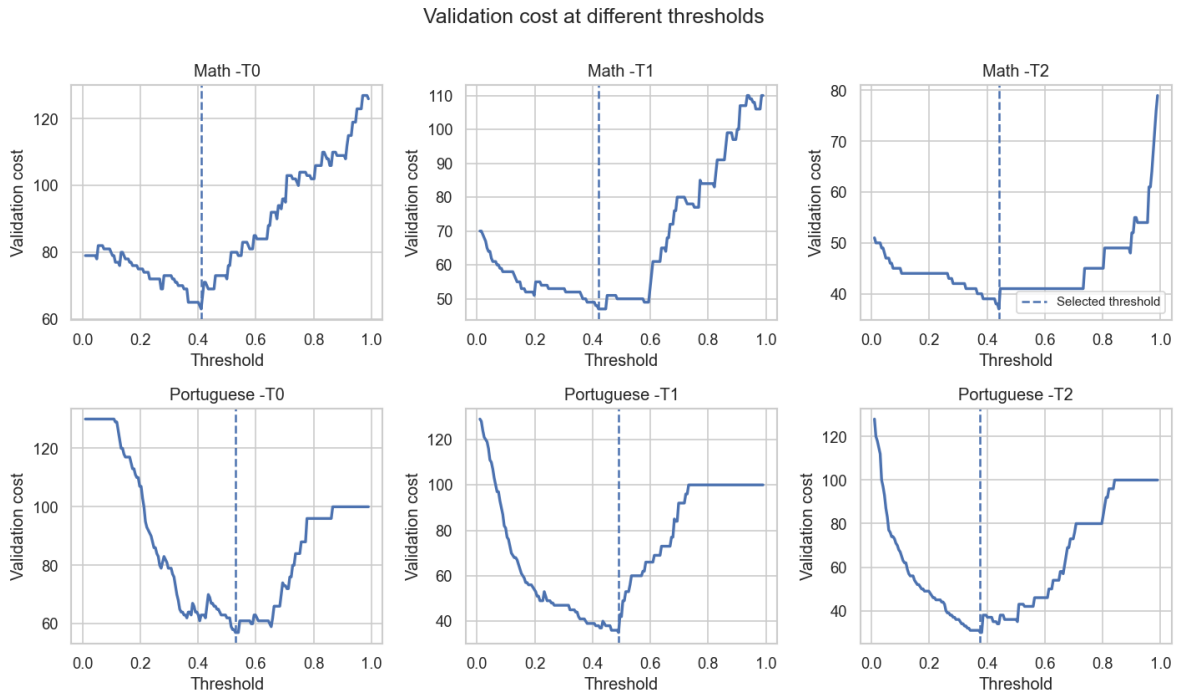
اگر هزینه کمک به هر دانش آموز c_h و هزینه از دست رفتن یک دانش آموز پرریسک c_l باشد، هزینه تصمیم به صورت زیر محاسبه می شود:

$$C(t) = c_h\big(TP(t) + FP(t)\big) + c_l FN(t). \qquad (۲)$$

آستانه های 0.01 تا 0.99 فقط روی مجموعه اعتبارسنجی بررسی شدند و آستانه با کمترین هزینه انتخاب شد. سپس همان آستانه روی آزمون اعمال شد. سه نسبت هزینه 2 : 1، 5 : 1 و 8 : 1 آزمایش شد. جدول زیر حالت مرجع $c_h = 1$ و $c_l = 5$ را نشان می دهد.

جدول ۱۵: نتیجه انتخاب آستانه برای نسبت هزینه 5 : 1

Recall	FN	Selected students	Test cost	Selected threshold	Scenario	course
0.731	7	39	74	0.411	T0	Math
0.885	3	31	46	0.421	T1	Math
1.000	0	29	29	0.441	T2	Math
0.750	5	29	54	0.530	T0	Portuguese
0.850	3	24	39	0.490	T1	Portuguese
1.000	0	31	31	0.376	T2	Portuguese



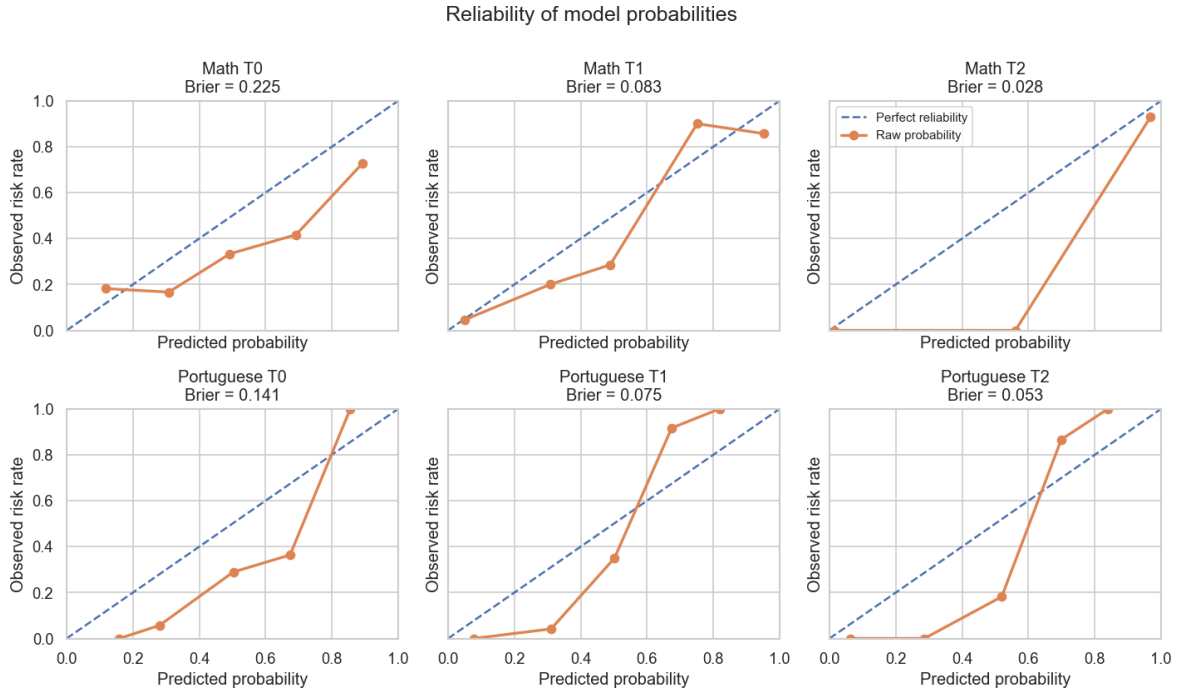
هرچه هزینه ترک مدرسه بیشتر شود آستانه باید کاهش یابد یا ثابت بماند تا دانش آموزان بیشتری مشمول کمک شوند و FN کاهش یابد. برای نمونه در پرتغالی T0، آستانه از 0.653 در نسبت 2 : 1 به 0.53 در 5 : 1 و 0.361 در 8 : 1 کاهش یافته است. آستانه ثابت 0.5 لزوما کم هزینه ترین تصمیم نیست. همچنین چون احتمال های خام مدل کاملا کالیبره نیستند انتخاب تجربی آستانه روی داده اعتبارسنجی از استفاده مستقیم یک فرمول نظری مطمئن تر است.

۱۳ پرسش سیزدهم

قابلیت اعتماد احتمال ها با میانگین احتمال پیش بینی شده، نرخ واقعی ریسک، امتیاز Brier (در اسلایدهای استاد نبود و با سرچ این معیار را پیدا کردم) و نمودار قابلیت اعتماد بررسی شد. امتیاز Brier کمتر بهتر است.

جدول ۱۶: خلاصه قابلیت اعتماد احتمال های خام

Brier	Mean predicted prob	Observed risk	Model	Scenario	Course
0.225	0.470	0.329	LR	T0	Math
0.083	0.354	0.329	LR	T1	Math
0.028	0.359	0.329	LR	T2	Math
0.141	0.363	0.154	RBF-SVM	T0	Portuguese
0.075	0.247	0.154	RF	T1	Portuguese
0.053	0.234	0.154	RF	T2	Portuguese



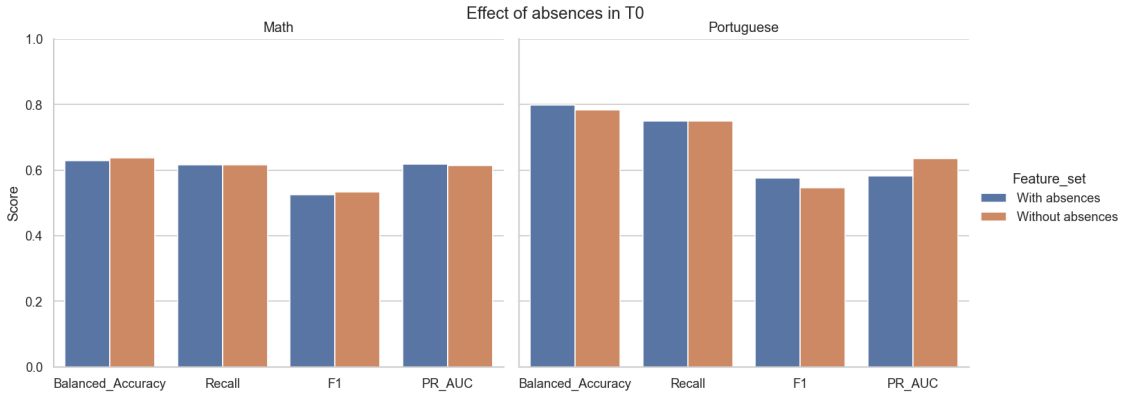
در T0 هر دو مدل ریسک را بیشتر برآورد می کنند. این موضوع در پرتغالی شدید است چون نرخ واقعی 0.154 ولی میانگین خروجی 0.363 است. با اضافه شدن نمرات، هم امتیاز Brier بهتر می شود و هم منحنی به قطر ایده آل نزدیک تر می گردد، هرچند احتمال پرتغالی حتی در T2 هنوز بیش برآورد دارد. علاوه بر این خروجی RBF-SVM در کد با اعمال تابع سیگموید روی امتیاز تصمیم ساخته شده و یک احتمال کالیبره شده رسمی نیست. بنابراین احتمال های خام، به ویژه در T0، برای تفسیر مستقیم به عنوان احتمال واقعی قابل اعتماد نیستند. راه حل مناسب، کالیبراسیون فقط با داده اعتبارسنجی و سپس بررسی دوباره نمودار قابلیت اعتماد و امتیاز Brier است.

۱۴ پرسش چهاردهم

مدل منتخب T0 یک بار با ویژگی absences و یک بار بدون آن و روی همان تقسیم داده آموزش داده شد.

جدول ۱۷: اثر حذف ویژگی absences در ابتدای ترم

FN	PR-AUC	F1	Recall	Balanced Accuracy	Feature set	Course
10	0.618	0.525	0.615	0.628	With absences	Math
10	0.613	0.533	0.615	0.638	Without absences	Math
5	0.583	0.577	0.750	0.798	With absences	Portuguese
5	0.635	0.545	0.750	0.784	Without absences	Portuguese



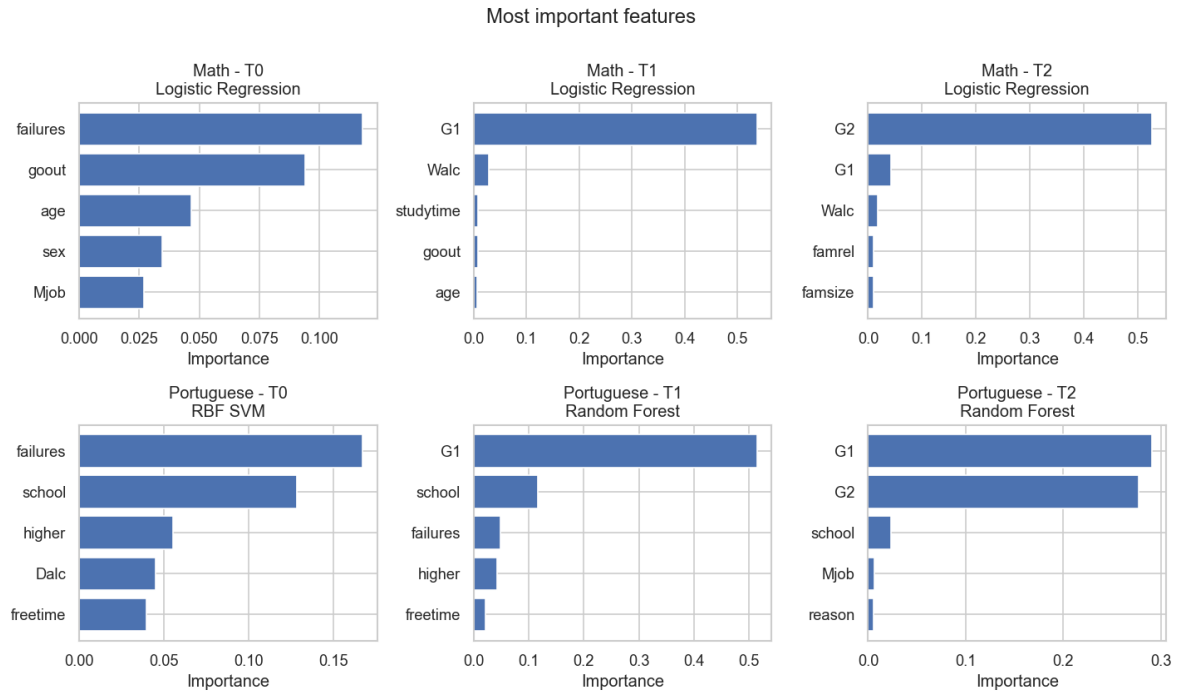
حذف absences در ریاضی F1 را فقط 0.008 بهتر کرده و در پرتغالی F1 را 0.032 کاهش داده است. Recall و تعداد FN در هر دو درس بدون تغییر مانده اند. بنابراین از نظر پیش بینی روی این تقسیم اثر absences کوچک و ناپایدار است. اما از نظر زمانی نکته مهم تری وجود دارد. اگر ستون absences مجموع absences های کل سال باشد، در ابتدای ترم در دسترس نیست و نگه داشتن آن در T0 نشت زمانی ایجاد می کند. برای یک سامانه واقعی باید آن را حذف کرد یا با absences های ترم قبل و absences های ثبت شده تا زمان تصمیم جایگزین کرد.

۱۵ پرسش پانزدهم

اهمیت ویژگی ها با جایگشت هر ویژگی روی آزمون و اندازه گیری افت Average Precision محاسبه شد. سه ویژگی اول هر حالت در جدول زیر آمده است و شکل زیر پنج ویژگی نخست را نشان می دهد.

جدول ۱۸: مهم ترین ویژگی ها بر اساس اهمیت

Importance	Feature	Rank	Scenario	Course
0.118	failures	1	T0	Math
0.094	goout	2	T0	Math
0.047	age	3	T0	Math
0.537	G1	1	T1	Math
0.028	Walc	2	T1	Math
0.008	studytime	3	T1	Math
0.525	G2	1	T2	Math
0.043	G1	2	T2	Math
0.017	Walc	3	T2	Math
0.167	failures	1	T0	Portuguese
0.128	school	2	T0	Portuguese
0.055	higher	3	T0	Portuguese
0.515	G1	1	T1	Portuguese
0.117	school	2	T1	Portuguese
0.048	failures	3	T1	Portuguese
0.291	G1	1	T2	Portuguese
0.277	G2	2	T2	Portuguese
0.023	school	3	T2	Portuguese



در T0، تعداد مردودی های قبلی (failures) مهم ترین ویژگی مشترک دو درس است. در ریاضی، میزان بیرون رفتن و(goout) سن (age) نیز اطلاعاتی اضافه می کنند و در پرتغالی، مدرسه (school) و higher مهم هستند. پس از G1، همین نمره با فاصله بسیار زیاد رتبه اول را می گیرد. در T2، G2 در ریاضی غالب است؛ ولی در پرتغالی G1 و G2 اهمیت نزدیک دارند. اهمیت بالای school در پرتغالی می تواند هم نشانه تفاوت واقعی محیط آموزشی و هم نشانه خطر وابستگی مدل به مدرسه باشد.

۱۶ پرسش شانزدهم

جدول زیر مشخصات میانگین نمونه های FN و FP مدل های منتخب را نشان می دهد. نبود ردیف FN در T2 به معنی تعداد صفر آن است.

جدول ۱۹: خطاهای مدل

Mean G3	Mean G2	Mean G1	Mean probability	Count	Error type	Scenario	Course
7.100	7.800	8.200	0.307	10	FN	T0	Math
13.368	13.316	13.158	0.656	19	FP	T0	Math
7.750	8.000	9.000	0.267	4	FN	T1	Math
11.600	11.000	9.600	0.686	5	FP	T1	Math
10.667	9.000	9.333	0.805	3	FP	T2	Math
6.800	8.000	7.800	0.356	5	FN	T0	Portuguese
11.353	10.471	10.529	0.590	17	FP	T0	Portuguese
6.000	7.500	7.750	0.432	4	FN	T1	Portuguese
10.500	9.500	8.833	0.575	6	FP	T1	Portuguese
10.429	9.000	8.857	0.578	7	FP	T2	Portuguese

در T0 مدل به نمرات دسترسی ندارد در نتیجه برخی دانش آموزان با نمرات واقعا پایین را کم خطر و برخی دانش آموزان با نمرات خوب را پرخطر تشخیص می دهد. پس از اضافه شدن نمرات خطاها به اطراف مرز قبولی نزدیک می شوند. در T2 هیچ دانش آموز پرریسکی از دست نرفته و همه خطاها FP هستند. میانگین G3 این FP ها فقط کمی بالاتر از 10

است، یعنی مدل بیشتر درباره دانش آموزان مرزی احتیاط کرده است. این جهت خطا برای یک سامانه حمایتی قابل قبول تر از FN است ولی موجب مصرف ظرفیت برنامه کمک آموزشی می شود.

۱۷ پرسش هفدهم

برای جنسیت، محل زندگی و مدرسه، نرخ مثبت درست TPR و نرخ FPR FP محاسبه و فاصله بیشترین و کمترین گروه گزارش شد. فاصله صفر به معنی برابری کامل روی همین نمونه آزمون است.

جدول ۲۰: شکاف عملکرد میان گروه ها

FPR gap	TPR gap	Property	Scenario	Course
0.278	0.188	sex	T0	Math
0.236	0.229	address	T0	Math
0.084	0.435	school	T0	Math
0.117	0.075	sex	T1	Math
0.110	0.057	address	T1	Math
0.109	0.174	school	T1	Math
0.036	0.000	sex	T2	Math
0.043	0.000	address	T2	Math
0.065	0.000	school	T2	Math
0.126	0.208	sex	T0	Portuguese
0.135	0.208	address	T0	Portuguese
0.429	0.055	school	T0	Portuguese
0.003	0.333	sex	T1	Portuguese
0.099	0.083	address	T1	Portuguese
0.200	0.132	school	T1	Portuguese
0.064	0.000	sex	T2	Portuguese
0.042	0.000	address	T2	Portuguese
0.142	0.000	school	T2	Portuguese

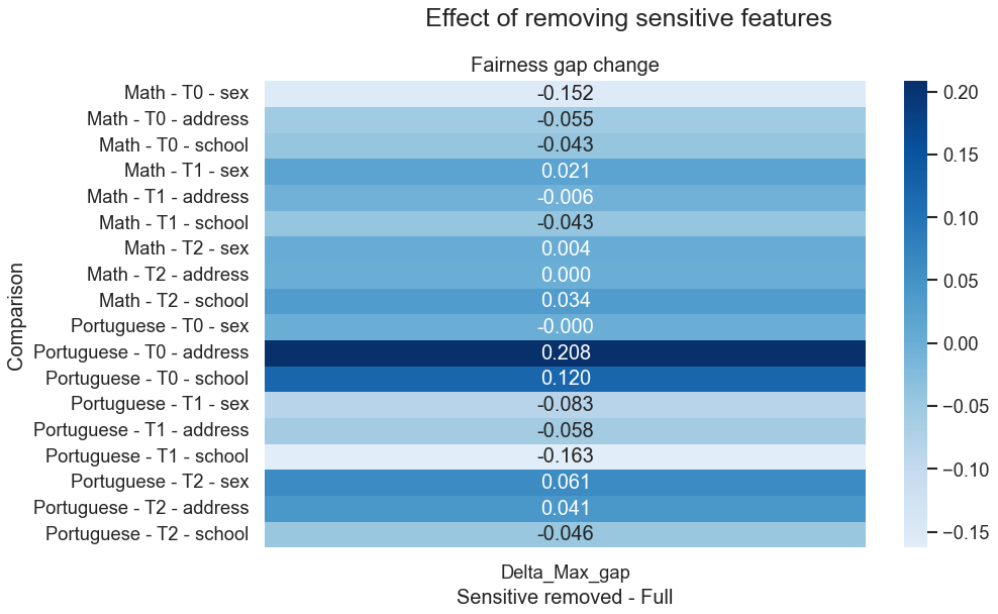
مدل در همه گروه ها به یک اندازه عادلانه عمل نمی کند. بزرگ ترین شکاف TPR ریاضی در T0 مربوط به مدرسه و برابر 0.435 است. در پرتغالی T0 شکاف FPR مدرسه 0.429 و در T1 شکاف TPR جنسیت 0.333 است. در T2 Recall همه گروه ها برابر شده چون Recall کل برابر 1 است با این حال شکاف FP، به ویژه شکاف 0.142 مدرسه در پرتغالی باقی مانده است. از آنجا که برخی زیرگروه ها کوچک هستند این شکاف ها عدم قطعیت بالایی دارند. پس نتیجه درست، رد یا تایید مطلق عدالت نیست بلکه نیاز به گزارش اندازه گروه و فاصله اطمینان هر گروه است.

۱۸ پرسش هجدهم

ویژگی های جنسیت، محل زندگی و مدرسه حذف شدند و همان مدل منتخب دوباره آموزش دید. جدول زیر تغییر عملکرد را نشان می دهد.

جدول ۲۱: اثر حذف ویژگی های حساس بر عملکرد

Course	Scenarion	F1 کامل	F1 حذف شده	تغییر F1	فراخوانی کامل	تغییر فراخوانی
Math	T0	0.525	0.567	+0.042	0.615	+0.038
Math	T1	0.830	0.885	+0.054	0.846	+0.038
Math	T2	0.945	0.945	0.000	1.000	0.000
Portuguese	T0	0.577	0.435	−0.142	0.750	−0.250
Portuguese	T1	0.762	0.756	−0.006	0.800	+0.050
Portuguese	T2	0.851	0.826	−0.025	1.000	−0.050



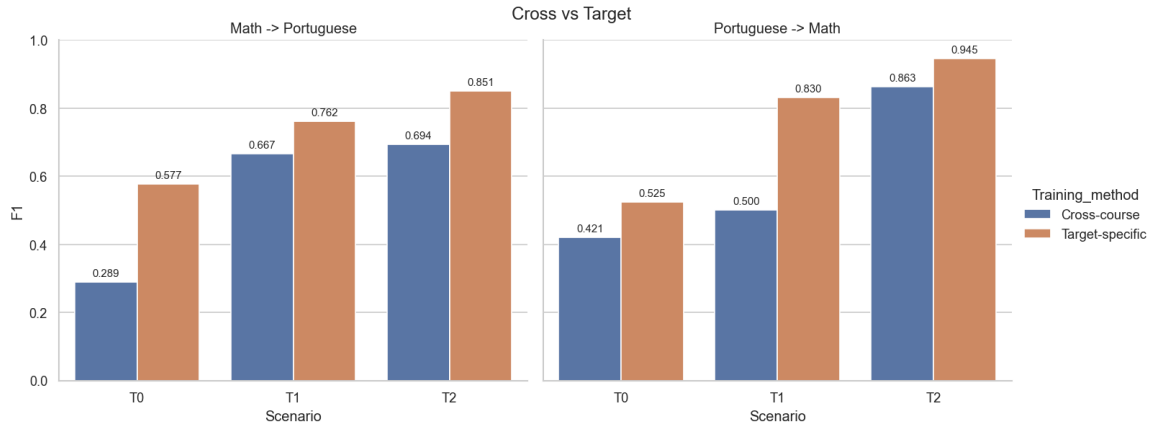
حذف ویژگی های حساس در ریاضی نه تنها افت ایجاد نکرده بلکه F1 در T0 و T1 بهتر شده است. در پرتغالی T0 افت شدید F1 و Recall دیده می شود. از نظر عدالت نیز حذف مستقیم همیشه مفید نیست. برای مثال شکاف مدرسه پرتغالی در T1 مقدار 0.162 کاهش یافته، اما در T0 شکاف محل زندگی 0.208 و شکاف مدرسه 0.12 افزایش یافته است. علت این است که ویژگی های دیگر می توانند جانشین ویژگی حساس باشند و حذف یک ستون اطلاعات گروهی را به طور کامل حذف نمی کند. بنابراین حذف کورکورانه راه حل کافی نیست و باید عملکرد و عدالت با هم سنجیده شوند و در صورت نیاز از روش های محدودیت عدالت، بازوزن دهی و تنظیم آستانه گروهی استفاده شود.

۱۹ پرسش نوزدهم

برای سنجش انتقال، مدل با داده آموزش و اعتبارسنجی یک درس آموزش دید و بدون بازآموزی روی آزمون درس دیگر ارزیابی شد. نتیجه با مدل آموزش دیده روی خود درس مقصد مقایسه شد.

جدول ۲۲: مقایسه انتقال بین درس ها با آموزش روی درس مقصد

Target F1	Cross F1	Target Recall	Cross Recall	Target Balanced Accuracy	Cross Balanced Accuracy	Scenario	Direction
0.577	0.289	0.750	0.700	0.798	0.564	T0	$Math- > Portuguese$
0.762	0.667	0.800	0.950	0.873	0.893	T1	$Math- > Portuguese$
0.851	0.694	1.000	0.850	0.968	0.870	T2	$Math- > Portuguese$
0.525	0.421	0.615	0.308	0.628	0.616	T0	$Portuguese- > Math$
0.830	0.500	0.846	0.346	0.876	0.664	T1	$Portuguese- > Math$
0.945	0.863	1.000	0.846	0.972	0.895	T2	$Portuguese- > Math$



در بیشتر حالت ها مدل آموزش دیده Target F1 بالاتری دارد. انتقال ریاضی به پرتغالی در Balanced Accuracy T1 و Recall بالاتری ایجاد کرده، اما F1 آن از 0.762 به 0.667 افت کرده است یعنی حساسیت بیشتر با هشدارهای اشتباه بیشتر همراه شده است. انتقال در جهت معکوس به ویژه در T1، ضعیف تر است. تفاوت نرخ ریسک دو درس، توزیع مدرسه ها و رابطه متفاوت ویژگی ها با نمره، انتقال مستقیم را دشوار می کند. بنابراین مدل بدون تنظیم مجدد به طور پایدار قابل تعمیم نیست و بهتر است روی درس هدف بازآموزی یا دست کم کالیبره شود.

۲۰ پرسش بیستم

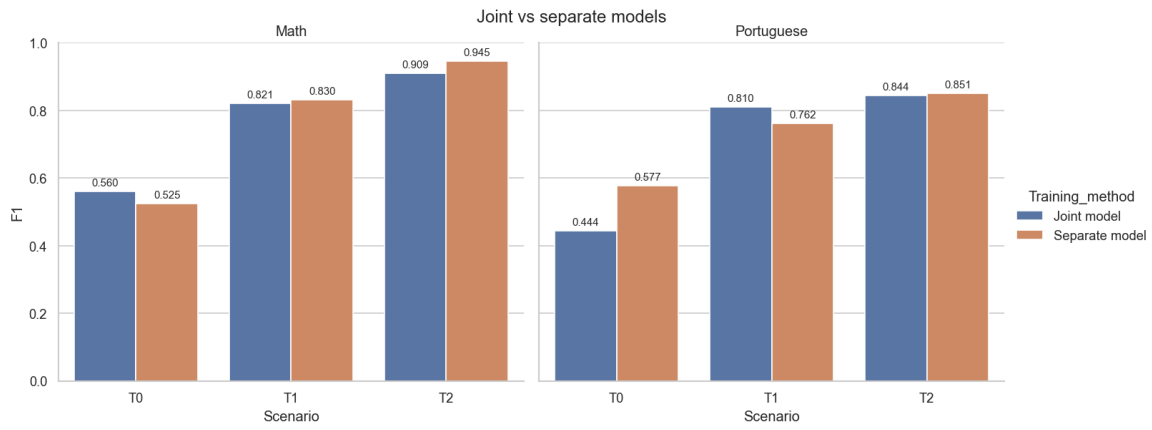
برای مدل مشترک، داده دو درس به صورت عمودی ترکیب و ستون course اضافه شد. تقسیم آموزش، اعتبارسنجی و آزمون هر درس حفظ شد تا هر دو روش روی همان دانش آموزان آزمون مقایسه شوند. مدل مشترک نیز با اعتبارسنجی انتخاب شد.

جدول ۲۳: خلاصه عملکرد مدل مشترک و مدل های جداگانه

F1 Separate/Joint	Separate Recall	Joint Recall	Separate Balanced Accuracy	Joint Balanced Accuracy	Joint model	Scenario
0.512/0.549	0.674	0.478	0.727	0.684	RF	T0
0.816/0.800	0.826	0.870	0.879	0.898	RF	T1
0.880/0.902	1.000	0.957	0.969	0.948	RF	T2

جدول ۲۴: مقایسه F1 مشترک و جداگانه برای هر درس

Best	Separate F1	Joint F1	Scenario	Course
Joint	0.525	0.560	T0	Math
Separate	0.577	0.444	T0	Portuguese
Separate	0.830	0.821	T1	Math
Joint	0.762	0.810	T1	Portuguese
Separate	0.945	0.909	T2	Math
Separate	0.851	0.844	T2	Portuguese



هیچ پاسخ یکسانی برای همه سناریوها وجود ندارد. مدل مشترک در T1 بهترین نتیجه کلی را دارد و F1 را از 0.8 به 0.816 می رساند. این بهبود احتمالا از افزایش حجم داده و الگوی مشترک قوی G1 ناشی می شود. در T0، تفاوت های پایه دو درس باعث می شود مدل جداگانه در مجموع بهتر باشد هرچند مدل مشترک برای ریاضی کمی بهتر شده است. در T2 نیز مدل های جداگانه روابط اختصاصی نمرات هر درس را بهتر ثبت می کنند. بنابراین اگر هدف بیشینه کردن عملکرد باشد، مدل های جداگانه برای T0 و T2 و مدل مشترک برای T1 انتخاب مناسب تری هستند. اگر سادگی عملیاتی یک مدل واحد مهم باشد، مدل مشترک باید همراه با ستون درس و گزارش جداگانه عملکرد هر درس استفاده شود.

۲۱ جمع بندی نهایی

نتایج نشان دادند که شناسایی دانش آموزان در معرض ریسک امکان پذیر است، اما کیفیت و ارزش عملی پیش بینی به زمان تصمیم وابستگی مستقیم دارد. در T0 مدل ها فقط یک ابزار غربالگری با عدم قطعیت قابل توجه هستند. اضافه شدن G1 بیشترین جهش اولیه را ایجاد می کند و T1 را به بهترین نقطه تعادل میان زودهنگام بودن و دقت تبدیل می سازد. G2 مدل را بسیار دقیق می کند ولی به علت نزدیکی زیاد به نمره نهایی فرصت مداخله را کاهش می دهد.

عدم توازن کلاس ها سبب شد دقت معمولی به تنهایی معیار مناسبی نباشد. ،Balanced Accuracy ،F1 Recall، PR-AUC و هزینه خطاها تصویر واقع بینانه تری ارائه کردند. رتبه بندی احتمال ریسک برای برنامه کمک آموزشی مفید بود اما احتمال های خام به ویژه در T0 به کالیبراسیون نیاز دارند. همچنین تحلیل عدالت نشان داد که عملکرد گروهی در برخی حالت ها متفاوت است و حذف ویژگی های حساس به تنهایی تضمین کننده عدالت نیست.