دانشگاه صنعتی شریف
دانشکده مهندسی برق

# مقدمه ای بر یادگیری ماشین

## پروژه - خوشه بندی

نیلوفر محمودی

۴۰۲۱۰۲۳۹۲

استاد درس:

محمد باقر شمس اللهی

نیمسال دوم ۱۴۰۴—۱۴۰۵

# ۱ مرحله اول : بارگذاری و پیش پردازش داده

در قسمت نخست داده ها بدون استفاده از برچسب از پیش تعیین شده خوشه بندی میشوند تا گروههای طبیعی دانش آموزان کشف شوند. در قسمت دوم، نمره نهایی G3 به عنوان یک متغیر پیوسته پیش بینی میشود. هر ردیف در داده ترکیبی یک مشاهده دانش آموز—درس است بنابراین اتصال دو فایل به صورت عمودی انجام شده و ادغام هویتی دانش آموزان صورت نگرفته است.

جدول ۱: ابعاد داده های اولیه و داده ترکیبی

| Dataset | Rows | Columns before course | Columns after course |
|---|---|---|---|
| Math | 395 | 33 | 34 |
| Portuguese | 649 | 33 | 34 |
| Combined | 1044 | 33 | 34 |

ستون course مشخص میکند که هر مشاهده متعلق به درس ریاضی یا پرتغالی است. وجود این ستون برای تحلیل تفاوت دو درس مهم است. پس از ترکیب، شش ویژگی مشتق شده زیر ساخته شدند:

$$\begin{aligned}
\text{ratio_fail_study} &= \frac{\text{failures}}{\text{studytime}},\\
\text{grade_improvement} &= G2 - G1,\\
\text{grade_average} &= \frac{G1 + G2}{2},\\
\text{absences_per_study} &= \frac{\text{absences}}{\text{studytime}},\\
\text{risk_G3_lt10} &= (G3 < 10),\\
\text{risk_G3_lt12} &= (G3 < 12).
\end{aligned}$$

دو پرچم ریسک مستقیما از G3 ساخته شده اند. از آنجا که خود G3 در خوشه بندی حضور دارد وارد کردن این دو پرچم باعث تکرار اطلاعات هدف میشد بنابراین این دو ویژگی از ماتریس خوشه بندی حذف شدند و فقط برای تفسیر پروفایل خوشه ها به کار رفتند. چهار ویژگی مشتق شده دیگر در مدل باقی ماندند.

در داده ترکیبی، 20 ستون عددی و 18 ستون رده ای شناسایی شد. ستونهای عددی با StandardScaler استاندارد شدند تا تفاوت مقیاس، محاسبه فاصله اقلیدسی را تحت تاثیر قرار ندهد. ستونهای رده ای نیز با OneHotEncoder و گزینه کدگذاری شد. ماتریس نهایی خوشه بندی دارای 1044 سطر و 65 ویژگی شد.

برای رگرسیون، ستون G3 از ماتریس ورودی حذف و به عنوان متغیر هدف در نظر گرفته شد. در نتیجه، ورودی رگرسیون 64 ویژگی داشت. داده با random_state=392 و نسبت 80 به 20 تقسیم شد؛ تعداد نمونه های آموزش و آزمون به ترتیب 835 و 209 بود.

# ۲ مرحله دوم : خوشه بندی

## ۱.۲ معیارهای ارزیابی

برای ارزیابی کیفیت خوشه ها از دو معیار استفاده شد. برای هر مشاهده $i$، اگر $a(i)$ میانگین فاصله آن تا اعضای خوشه خودش و $b(i)$ کمترین میانگین فاصله آن تا خوشه دیگر باشد، امتیاز سیلوئت به صورت زیر تعریف میشود:

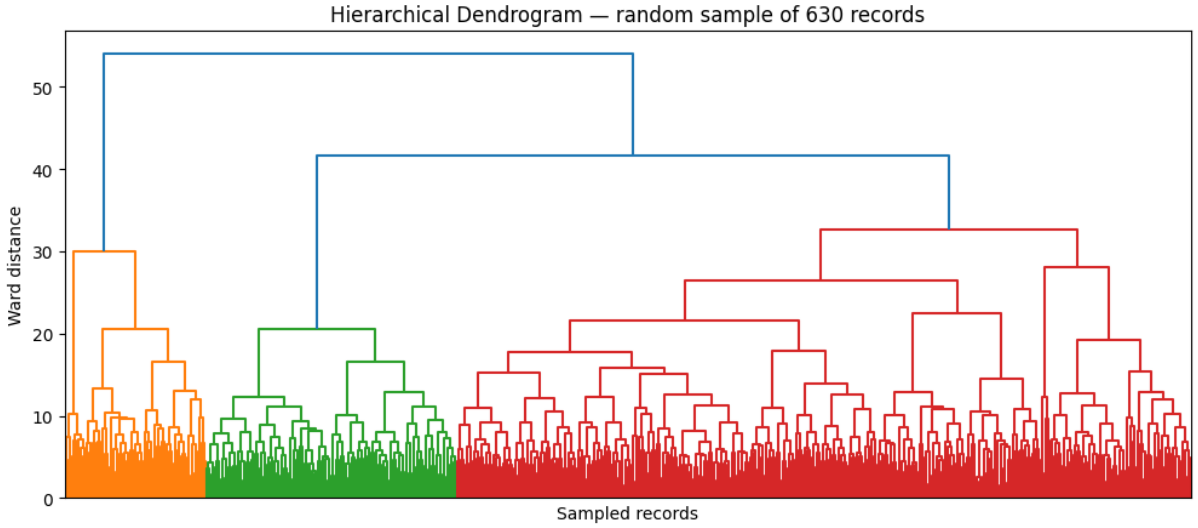
$$s(i) = \frac{b(i) - a(i)}{\max\{a(i), b(i)\}}.$$

مقدار بزرگتر سیلوئت بهتر است. مقدار نزدیک 1 جدایی مناسب، مقدار نزدیک 0 همپوشانی خوشه ها و مقدار منفی انتساب نامناسب را نشان میدهد. شاخص Davies–Bouldin شباهت درون خوشه ای را نسبت به فاصله بین خوشه ها اندازه میگیرد و مقدار کمتر آن بهتر است. استفاده همزمان از این دو معیار مانع نتیجه گیری ما را بهتر می کند.

## ۲.۲ چهار روش خوشه بندی

در K-Means تعداد خوشه ها برابر 2، تعداد شروعهای تصادفی برابر 50 در نظر گرفته شد. این روش 632 مشاهده را در خوشه 0 و 412 مشاهده را در خوشه 1 قرار داد. میانگین G3 در خوشه 0 برابر 13.46 و در خوشه 1 برابر 8.092 بود. بنابراین خوشه 0 با عنوان «عملکرد بالاتر و ریسک کمتر» و خوشه 1 با عنوان «عملکرد پایین تر و ریسک بیشتر» نامگذاری شد.

در خوشه بندی Hierarchical از پیوند Ward استفاده شد. خوشه 0 شامل 820 مشاهده با میانگین G3 برابر 10.306 بود و خوشه 1 شامل 224 مشاهده با میانگین G3 برابر 15.134 شد. بنابراین خوشه 0 گروه عملکرد پایین تر و خوشه 1 گروه عملکرد بالاتر نامگذاری شد. شکل زیر دندروگرام نمونه تصادفی 630 مشاهده را نشان میدهد.




دو روش دیگر، GMM با کوواریانس کامل و روش Fuzzy C-Means بودند. GMM خوشه هایی با اندازه 779 و 265 تشکیل داد. روش فازی پس از 14 تکرار همگرا شد و برچسب سخت حاصل از بیشترین عضویت، اندازه های 488 و 556 را ایجاد کرد. با این حال ضرایب عضویت نخستین مشاهده ها در هر دو خوشه برابر 0.5 بودند که نشان میدهد روش فازی در فضای 65 بعدی اعتماد مناسبی برای انتساب نرم نمونه ها پیدا نکرده است.

جدول ۲: خوشه های حاصل از چهار روش

| Method | Cluster interpretation | Count | G1 | G2 | G3 | Study time | Failures | Absences |
|---|---|---|---|---|---|---|---|---|
| K-Means | Higher performance / Lower risk | 632 | 12.930 | 13.101 | 13.460 | 2.161 | 0.033 | 3.430 |
| K-Means | Lower performance / Higher risk | 412 | 8.580 | 8.400 | 8.092 | 1.677 | 0.619 | 5.976 |
| Hierarchical | Lower performance / Higher risk | 820 | 10.334 | 10.280 | 10.306 | 1.887 | 0.323 | 4.811 |
| Hierarchical | Higher performance / Lower risk | 224 | 14.433 | 14.781 | 15.134 | 2.277 | 0.049 | 3.058 |
| GMM | Higher performance / Lower risk | 779 | 11.950 | 12.041 | 12.403 | 2.039 | 0.000 | 3.702 |
| GMM | Lower performance / Higher risk | 265 | 9.049 | 8.909 | 8.223 | 1.770 | 1.042 | 6.589 |
| Fuzzy C-Means | Lower performance / Higher risk | 488 | 8.910 | 8.744 | 8.541 | 1.723 | 0.531 | 5.725 |
| Fuzzy C-Means | Higher performance / Lower risk | 556 | 13.236 | 13.442 | 13.800 | 2.187 | 0.031 | 3.302 |

جدول پروفایل ها الگوی ثابتی را در هر چهار روش نشان میدهد: گروه با نمره نهایی پایین تر، شکستهای قبلی و غیبت بیشتری دارد و زمان مطالعه آن کمتر است. بنابراین نامگذاری خوشه ها فقط بر اساس G3 نیست و چند شاخص رفتاری و تحصیلی آن را تایید میکنند.

جدول ۳: مقایسه کیفیت چهار روش خوشه بندی

| Method | Silhouette | Davies–Bouldin | Silhouette rank | DB rank | Total rank |
|---|---|---|---|---|---|
| K-Means | 0.122 | 2.728 | 2 | 1 | 3 |
| GMM | 0.128 | 3.086 | 1 | 4 | 5 |
| Fuzzy C-Means | 0.107 | 2.755 | 3 | 2 | 5 |
| Hierarchical | 0.041 | 2.809 | 4 | 3 | 7 |

GMM بیشترین سیلوئت را دارد، اما بدترین مقدار Davies–Bouldin را ثبت کرده است. K-Means در سیلوئت رتبه دوم و در Davies–Bouldin رتبه نخست را دارد و با مجموع رتبه 3 بهترین روش کلی است. در عین حال بیشترین سیلوئت فقط 0.128 است پس خوشه ها همپوشانی زیادی دارند و نتیجه باید به عنوان یک تقسیم بندی نباید به دو گروه طبیعی کاملا جدا تفسیر شود.

## ۳ مرحله سوم : رگرسیون

چهار مدل Random Forest، XGBoost، رگرسیون خطی و Gradient Boosting برای پیش بینی G3 آموزش داده شدند. Random Forest با 500 درخت، XGBoost با 500 برآوردگر و نرخ یادگیری 0.03، و Gradient Boosting با 300 برآوردگر و نرخ یادگیری 0.03 اجرا شدند. معیارهای ارزیابی عبارت بودند از:

$$MAE = \frac{1}{n}\sum_{i=1}^{n}|y_i - \hat{y}_i|,$$

$$RMSE = \sqrt{\frac{1}{n}\sum_{i=1}^{n}(y_i - \hat{y}_i)^2},$$

$$R^2 = 1 - \frac{\sum_{i=1}^{n}(y_i - \hat{y}_i)^2}{\sum_{i=1}^{n}(y_i - \bar{y})^2}.$$

جدول ۴: عملکرد مدلهای پایه رگرسیون روی مجموعه آزمون

| Model | MAE | RMSE | $R^2$ |
|---|---|---|---|
| Random Forest | 0.997 | 1.654 | 0.843 |
| Gradient Boosting | 1.035 | 1.714 | 0.832 |
| XGBoost | 1.029 | 1.724 | 0.830 |
| Linear Regression | 1.097 | 1.802 | 0.814 |

Random Forest در هر سه معیار بهترین نتیجه را به دست آورد. مقدار $MAE = 0.997$ یعنی میانگین قدر مطلق خطای پیش بینی تقریبا یک نمره است. مقدار $RMSE = 1.654$ از MAE بزرگتر است و وجود تعدادی خطای بزرگتر را نشان میدهد. مقدار $R^2 = 0.843$ نیز بیان میکند که مدل حدود $84.3\%$ از تغییرات نمره نهایی مجموعه آزمون را توضیح میدهد. برتری مدلهای درختی نسبت به رگرسیون خطی نشان میدهد که رابطه ویژگیها با G3 کاملا خطی و جمع پذیر نیست.

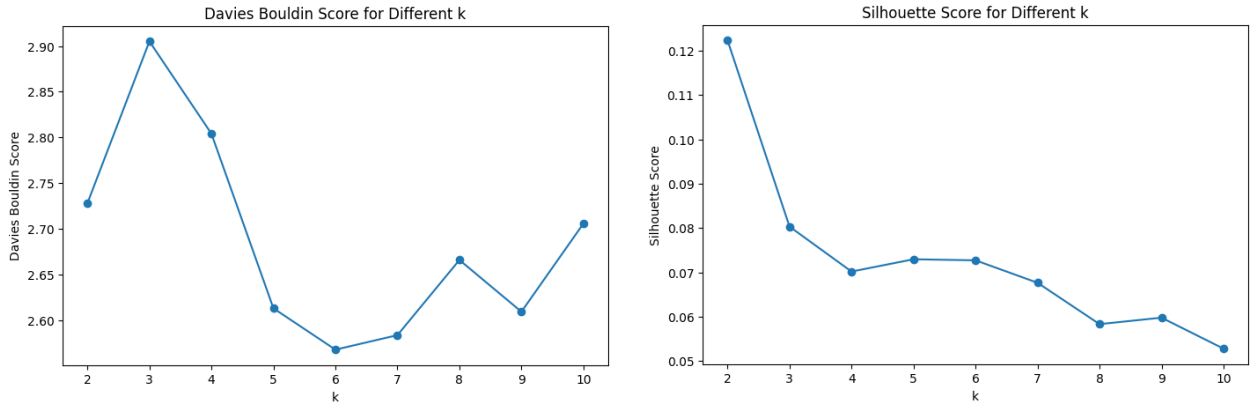
# ۴ پرسش های بخش دوم

## ۱.۴ پرسش اول

انتخاب اولیه $k = 2$ تفسیر آموزشی ساده ای ایجاد میکند: دانش آموزان با عملکرد بالاتر و ریسک کمتر در برابر دانش آموزان با عملکرد پایین تر و ریسک بیشتر. برای ارزیابی تجربی این انتخاب، مقادیر $k$ از 2 تا 10 با دو معیار سیلوئت و Davies–Bouldin بررسی شدند.

جدول ۵: نتایج انتخاب تعداد خوشه ها برای $k = 2$ تا $k = 10$

| $k$ | Silhouette | Davies–Bouldin | Silhouette rank | DB rank | Total rank |
|---|---|---|---|---|---|
| 2 | 0.122 | 2.728 | 1 | 7 | 8 |
| 3 | 0.080 | 2.905 | 2 | 9 | 11 |
| 4 | 0.070 | 2.804 | 5 | 8 | 13 |
| 5 | 0.073 | 2.613 | 3 | 4 | 7 |
| 6 | 0.073 | 2.567 | 4 | 1 | 5 |
| 7 | 0.068 | 2.583 | 6 | 2 | 8 |
| 8 | 0.058 | 2.666 | 8 | 5 | 13 |
| 9 | 0.060 | 2.609 | 7 | 3 | 10 |
| 10 | 0.053 | 2.706 | 9 | 6 | 15 |




(آ) تغییر امتیاز سیلوئت (ب) تغییر شاخص Davies–Bouldin

شکل ۱: مقایسه معیارهای انتخاب $k$ در بازه 2 تا 10

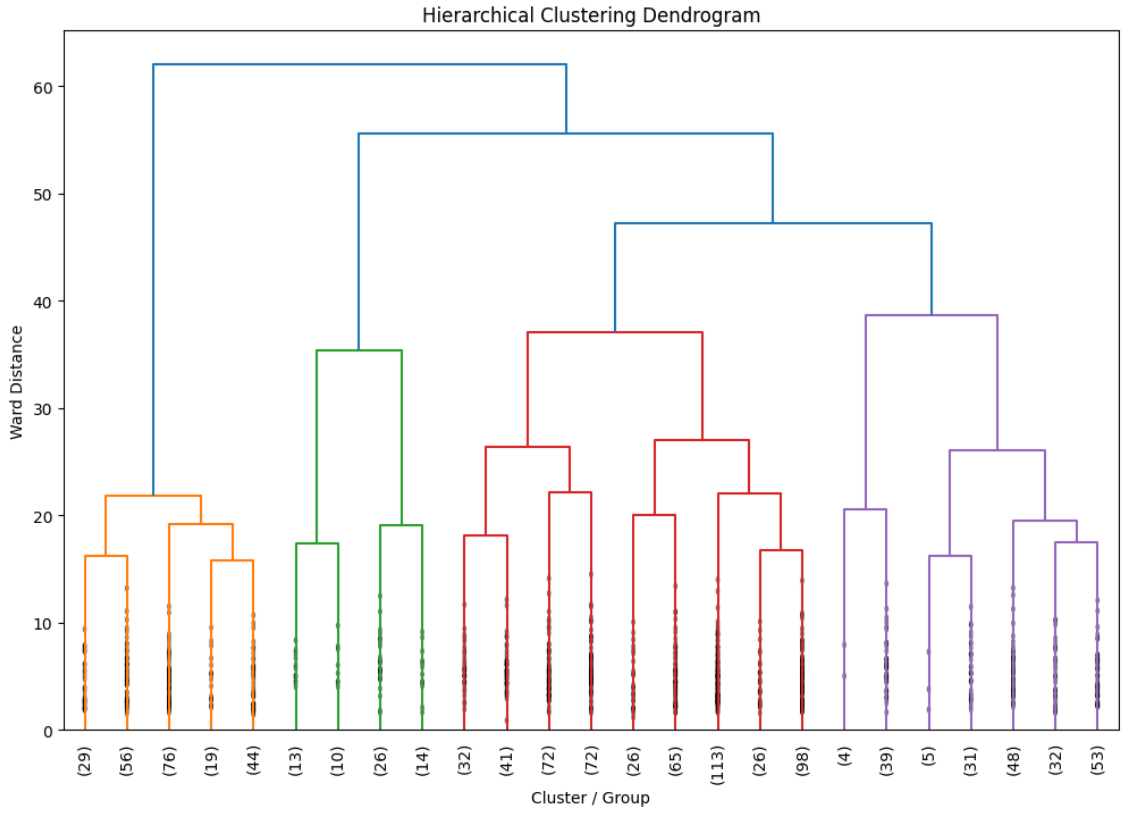
بیشترین سیلوئت در $k = 2$ و کمترین Davies–Bouldin در $k = 6$ به دست آمده است. بر اساس مجموع رتبه های دو معیار، $k = 6$ با رتبه کل 5 انتخاب میشود. با این حال افزایش تعداد خوشه ها از 2 به 6، سیلوئت را از $0.122$ به $0.073$ کاهش میدهد که افتی حدود $40.2\%$ است در مقابل، بهبود Davies–Bouldin فقط حدود $5.9\%$ است. بنابراین نتیجه نهایی وابسته به هدف است. برای کمینه کردن شاخص Davies–Bouldin و ایجاد گروههای جزئی تر، $k = 6$ مناسب تر است، اما برای جدایی کلی و تفسیر ساده آموزشی $k = 2$ همچنان انتخاب قابل دفاع تری است. ادامه پروژه مطابق صورت سوال با $k = 2$ انجام شده است.

## ۲.۴ پرسش دوم

جدول ۶: مقایسه مستقیم دو روش اصلی خوشه بندی

| Method | Silhouette | Davies–Bouldin | Cluster 0 size | Cluster 1 size |
|---|---|---|---|---|
| K-Means | 0.122 | 2.728 | 632 | 412 |
| Hierarchical | 0.041 | 2.809 | 820 | 224 |

K-Means هم سیلوئت بالاتر و هم Davies–Bouldin پایین تری دارد. علاوه بر این اندازه دو خوشه آن متعادل تر است و جداسازی گروه عملکرد پایین و بالا را روشن تر نشان می دهد. روش Hierarchical به علت تصمیم های ادغام برگشت ناپذیر و حساسیت به هندسه فضایی، یک خوشه بسیار بزرگ 820 عضوی و یک خوشه 224 عضوی ایجاد کرده است. بنابراین برای این پروژه K-Means ترجیح داده می شود.




شکل ۲: دندروگرام فشرده خوشه بندی Hierarchical با پیوند Ward

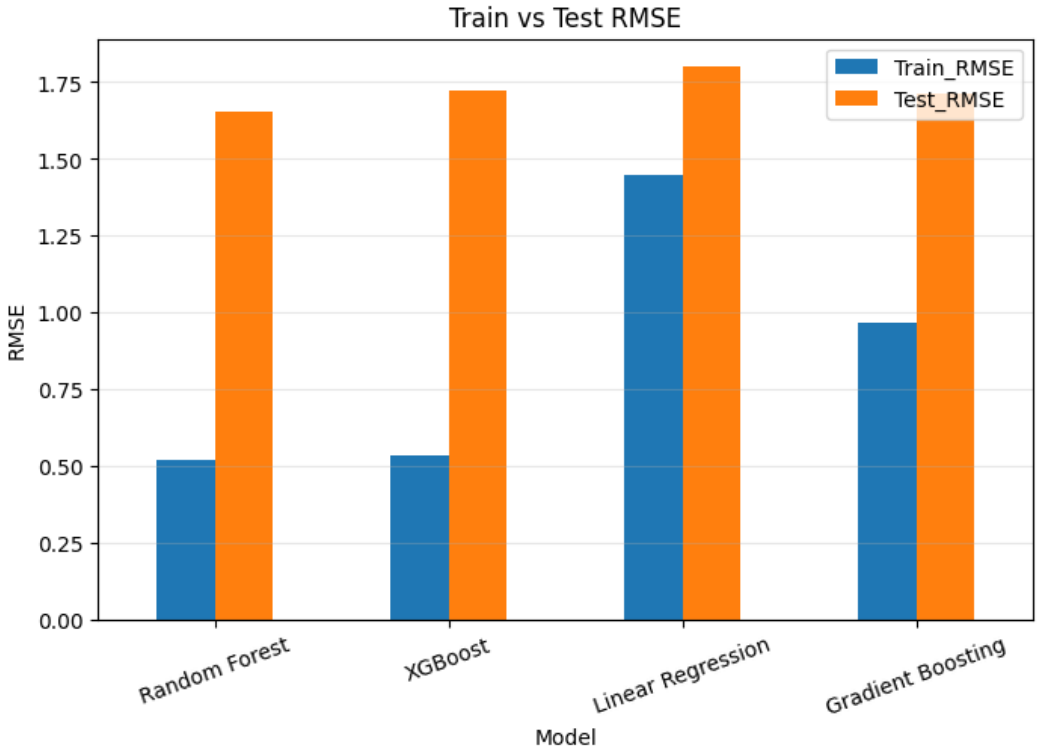
دندروگرام اطلاعاتی را ارائه میکند که در K-Means دیده نمی شود. ترتیب ادغام گروه ها، فاصله ادغام و وجود زیرگروه ها. برش افقی دندروگرام در ارتفاع های مختلف تعداد خوشه های متفاوتی ایجاد میکند. در شکل چند ادغام بزرگ در سطوح بالای فاصله دیده می شود اما یک شکاف کاملا غالب و بدون ابهام برای تعیین تعداد خوشه ها وجود ندارد. این مشاهده با پایین بودن سیلوئت سازگار است.

## ۳.۴ پرسش سوم

از نظر عملکرد روی مجموعه آزمون Random Forest بهترین مدل است. این مدل می تواند رابطه های غیرخطی، آستانه ها و برهم کنش میان نمره های قبلی، غیبت، زمان مطالعه و ویژگی های رده ای را بدون تعریف دستی همه برهم کنش ها یاد بگیرد. تجمیع تعداد زیادی درخت نیز خطای هر درخت منفرد را کاهش می دهد.

جدول ۷: مقایسه خطای آموزش و آزمون برای تحلیل بایاس—واریانس

| Model | Train RMSE | Test RMSE | RMSE gap | Train $R^2$ | Test $R^2$ | $R^2$ gap |
|---|---|---|---|---|---|---|
| Random Forest | 0.520 | 1.654 | 1.134 | 0.981 | 0.843 | 0.138 |
| Gradient Boosting | 0.964 | 1.714 | 0.750 | 0.935 | 0.832 | 0.103 |
| XGBoost | 0.533 | 1.724 | 1.190 | 0.980 | 0.830 | 0.150 |
| Linear Regression | 1.448 | 1.802 | 0.354 | 0.853 | 0.814 | 0.039 |




شکل ۳: مقایسه RMSE آموزش و آزمون مدلهای رگرسیون

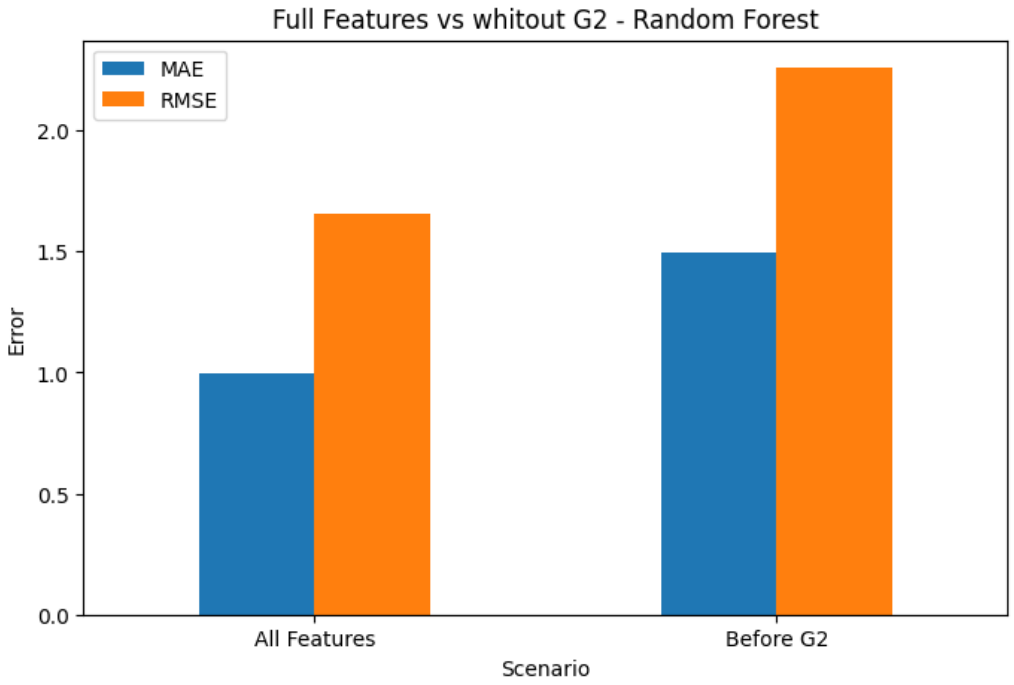
Random Forest و XGBoost خطای آموزش بسیار کمی دارند، اما شکاف آموزش—آزمون آنها به ترتیب 1.134 و 1.190 است پس واریانس آنها نسبتا زیاد است. رگرسیون خطی کوچکترین شکاف را دارد اما خطای آموزش و آزمون هر دو بالا هستند. این الگو نشان دهنده بایاس بیشتر و واریانس کمتر است. Gradient Boosting از نظر تعادل بایاس—واریانس میانه تر است چون خطای آزمون آن فقط 0.06 بیشتر از Random Forest است اما شکاف RMSE آن 0.384 کمتر است. در نتیجه Random Forest بهترین دقت آزمون را دارد ولی Gradient Boosting متعادل ترین سازش میان برازش و تعمیم را نشان میدهد.

## ۴.۴ پرسش چهارم

برای شبیه سازی پیش بینی زودهنگام سه ستون G2، grade_improvement و grade_average حذف شدند چون دو ویژگی مشتق شده اخیر نیز از G2 استفاده میکنند. تعداد ویژگیها از 64 به 61 کاهش یافت و Random Forest با همان تقسیم آموزش و آزمون دوباره آموزش داده شد.

جدول ۸: اثر حذف اطلاعات G2 بر عملکرد Random Forest

| Scenario | MAE | RMSE | $R^2$ |
|---|---|---|---|
| All features | 0.997 | 1.654 | 0.843 |
| Before G2 | 1.495 | 2.260 | 0.707 |
| Absolute change | +0.4985 | +0.6058 | −0.1360 |




شکل ۴: مقایسه خطای مدل کامل و مدل پیش بینی زودهنگام بدون G2

حذف اطلاعات G2 مقدار MAE را حدود 50% و RMSE را حدود 36.6% افزایش داده و $R^2$ را از 0.843 به 0.707 کاهش داده است. این افت قابل توجه نشان می دهد G2 خلاصه بسیار قوی از وضعیت نزدیک به پایان ترم است. با این حال، $R^2 = 0.707$ نشان میدهد پیش بینی زودهنگام هنوز ارزش عملی دارد.

برای بهبود این سناریو می توان از ارزیابی های کوتاه و کم هزینه در ابتدای ترم، روند هفتگی غیبت و زمان مطالعه، ویژگی های تغییرات زمانی، تنظیم ابرپارامترها با اعتبارسنجی متقاطع، مدلهای ترکیبی و برآورد عدم قطعیت استفاده کرد. همچنین بهتر است ویژگیهای رفتاری فقط تا زمان تصمیم جمع آوری شوند تا نشت زمانی رخ ندهد.

## ۵.۴ پرسش پنجم

برای سنجش اثر ویژگی های مشتق شده عملکرد XGBoost در دو حالت با چهار ویژگی مشتق شده قابل استفاده و بدون آنها مقایسه شد. دو پرچم ریسک از ابتدا در رگرسیون حضور نداشتند بنابراین تعداد ویژگیها از 64 به 60 کاهش یافت.

جدول ۹: اثر حذف ویژگیهای مشتق شده بر XGBoost

| Feature set | MAE | RMSE | $R^2$ |
|---|---|---|---|
| With derived features | 1.029 | 1.724 | 0.830 |
| Without derived features | 1.048 | 1.738 | 0.827 |
| Change after removal | +0.0190 | +0.0148 | −0.0029 |

ویژگی های مشتق شده اثر مثبت اما کوچک دارند. حذف آن ها MAE را حدود 1.8% و RMSE را کمتر از 1% افزایش می دهد. علت کوچک بودن اثر این است که XGBoost می تواند بسیاری از رابطه های غیرخطی و برهم کنش های میان متغیرهای اصلی را خودش یاد بگیرد. علاوه بر این، grade_average و grade_improvement ترکیبهای قطعی از G1 و G2 هستند و اطلاعات کاملا جدیدی ایجاد نمی کنند. با وجود این همین بازنمایی ها مسیر یادگیری را کمی ساده کرده و نتیجه را بهبود داده اند.

## ۶.۴ پرسش ششم

ترکیب داده ها می تواند باعث شود مدل بیشتر از گروه های پرتعداد یاد بگیرد. در داده کامل تعداد مشاهدات درس پرتغالی بیشتر از ریاضی است. همچنین توزیع مدرسه و درس متوازن نیست: گروه Math–MS فقط 46 مشاهده دارد در حالی که گروه Portuguese–GP شامل 423 مشاهده است.

جدول ۱۰: توزیع مشاهده ها بر حسب مدرسه و درس

| School | Math | Portuguese | Total |
|---|---|---|---|
| GP | 349 | 423 | 772 |
| MS | 46 | 226 | 272 |
| Total | 395 | 649 | 1044 |

برای تشخیص بایاس MAE و RMSE مدل Random Forest در هر گروه جداگانه محاسبه شد.

جدول ۱۱: عملکرد مدل پایه در گروههای درس و مدرسه

| Grouping | Group | Test count | MAE | RMSE |
|---|---|---|---|---|
| Course | Math | 70 | 0.958 | 1.458 |
| Course | Portuguese | 139 | 1.016 | 1.745 |
| School | GP | 148 | 0.927 | 1.445 |
| School | MS | 61 | 1.167 | 2.077 |

شکاف خطا بین دو درس محدودتر از شکاف دو مدرسه است. شکاف RMSE درس برابر 0.2865، اما شکاف مدرسه برابر 0.6320 است. بنابراین نگرانی اصلی در این اجرا عملکرد ضعیف تر مدل برای مدرسه MS است. این اختلاف می تواند از کم بودن تعداد نمونه، تفاوت توزیع ویژگی ها یا رابطه متفاوت ویژگی ها با نمره در دو مدرسه ناشی شود.

برای کاهش بایاس به هر ترکیب درس—مدرسه وزنی معکوس با فراوانی آن در داده آموزش داده شد. وزن های گروه های Math–GP، Math–MS، Portuguese–GP و Portuguese–MS به ترتیب 0.722، 5.799، 0.623 و 1.193 بودند.

جدول ۱۲: مقایسه شکاف خطا قبل و بعد از وزن دهی گروهی

| Grouping | MAE gap before | MAE gap after | RMSE gap before | RMSE gap after |
|---|---|---|---|---|
| Course | 0.058 | 0.051 | 0.286 | 0.202 |
| School | 0.241 | 0.190 | 0.632 | 0.536 |

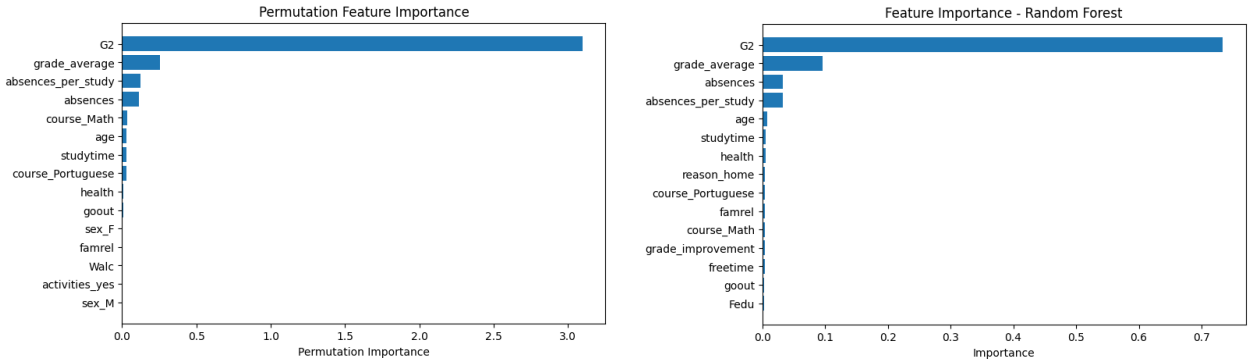
وزن دهی، شکاف RMSE درس را حدود 29% و شکاف RMSE مدرسه را حدود 15% کاهش داده است. در مقابل خطای گروه های پرتعداد اندکی افزایش یافته است برای مثال RMSE مدرسه GP از 1.445 به 1.493 رسید. این نتیجه سازش میان عدالت گروهی و بهترین دقت کلی را نشان می دهد. برای اطمینان بیشتر باید نتایج با چند تقسیم تصادفی، اعتبارسنجی طبقه بندی شده بر اساس درس و مدرسه، و فاصله اطمینان گزارش شوند.

## ۷.۴ پرسش هفتم

دو روش برای اهمیت سنجی اجرا شد. روش نخست اهمیت مبتنی بر کاهش ناخالصی در Random Forest است. روش دوم اهمیت جایگشتی است که هر ویژگی را در داده آزمون به هم می زند و افت عملکرد را اندازه میگیرد. توافق این دو روش، نتیجه را قابل اعتمادتر می کند.

جدول ۱۳: ده ویژگی اول در دو روش اهمیت سنجی

| Feature | Model importance | Permutation importance | Model rank | Permutation rank | Average rank |
|---|---|---|---|---|---|
| G2 | 0.734 | 3.098 | 1 | 1 | 1.0 |
| grade_average | 0.096 | 0.255 | 2 | 2 | 2.0 |
| absences | 0.033 | 0.115 | 3 | 4 | 3.5 |
| absences_per_study | 0.032 | 0.125 | 4 | 3 | 3.5 |
| age | 0.008 | 0.030 | 5 | 6 | 5.5 |
| studytime | 0.005 | 0.028 | 6 | 7 | 6.5 |
| health | 0.005 | 0.008 | 7 | 9 | 8.0 |
| course_Math | 0.005 | 0.034 | 11 | 5 | 8.0 |
| course_Portuguese | 0.005 | 0.027 | 9 | 8 | 8.5 |
| famrel | 0.005 | 0.005 | 10 | 12 | 11.0 |




(آ) اهمیت داخلی Random Forest (ب) اهمیت جایگشتی روی آزمون

شکل ۵: مقایسه دو روش اهمیت سنجی ویژگیها

هر دو روش با فاصله زیاد G2 را مهم ترین ویژگی معرفی می کنند. در اهمیت جایگشتی، بر هم زدن G2 مقدار RMSE را حدود 3.098 واحد بدتر می کند. پس از آن میانگین نمره های قبلی، غیبت و نسبت غیبت به زمان مطالعه قرار دارند. از نظر آموزشی ارزیابی دوم نزدیک ترین نشانه از وضعیت نهایی است و الگوی غیبت میتواند علامت هشدار مکمل باشد. با این حال اهمیت ویژگی با اثر علّی برابر نیست. همچنین همبستگی زیاد G2 با grade_average باعث تقسیم یا پنهان شدن بخشی از اهمیت میان این دو متغیر می شود بنابراین مقادیر خام اهمیت باید همراه با ساختار همبستگی تفسیر شوند.

## ۸.۴ پرسش هشتم

برای آزمایش حساسیت، به 12% از ردیف ها، یعنی 125 مشاهده در ویژگی های عددی نویز گاوسی افزوده شد. شدت نویز از 1 تا 3 تغییر کرد. با افزایش شدت، سیلوئت به طور یکنواخت کاهش و Davies–Bouldin افزایش یافت.

جدول ۱۴: حساسیت K-Means به شدت نویز

| Noise strength | Silhouette | Davies–Bouldin |
|---|---|---|
| 1.0 | 0.109 | 2.826 |
| 1.5 | 0.103 | 2.905 |
| 2.0 | 0.098 | 2.985 |
| 2.5 | 0.095 | 3.054 |
| 3.0 | 0.093 | 3.118 |

برای مقابله با نویز، یک امتیاز فاصله از میانه برای رتبه بندی ردیف ها محاسبه شد و ردیف های با بیشترین امتیاز حذف شدند. بهترین نرخ برش 12% بود و دقت شناسایی ردیف های تزریق شده حدود 0.952 به دست آمد.

جدول ۱۵: اثر نویز و برش مقاوم بر خوشه بندی

| Data | Silhouette | Davies–Bouldin |
|---|---|---|
| Original | 0.122 | 2.728 |
| Noisy | 0.093 | 3.118 |
| After robust trimming | 0.113 | 2.767 |

برش مقاوم بخش عمده افت خوشه بندی را جبران کرد هرچند نتیجه کاملا به سطح داده اصلی بازنگشت. همان نویز در داده آموزش رگرسیون Random Forest اثر شدیدی ایجاد نکرد.

جدول ۱۶: اثر نویز و برش مقاوم بر رگرسیون

| Data | MAE | RMSE | $R^2$ |
|---|---|---|---|
| Original | 0.997 | 1.654 | 0.843 |
| Noisy train | 0.993 | 1.620 | 0.850 |
| After robust trimming | 0.992 | 1.633 | 0.847 |

بهبود کوچک رگرسیون پس از افزودن نویز نباید به معنی مفید بودن نویز تلقی شود این تفاوت می تواند حاصل تصادف نمونه گیری و خاصیت تجمیعی Random Forest باشد و برای نتیجه گیری به تکرار آزمایش نیاز دارد. در همین اجرای کنترل شده، خوشه بندی بیشتر آسیب دید، زیرا مراکز K-Means مستقیما با فاصله اقلیدسی و میانگین تعیین می شوند و نقاط پرت می توانند آنها را جابه جا کنند. Random Forest به دلیل نمونه گیری و تجمیع درخت ها مقاوم تر بود.

## ۹.۴ پرسش نهم

ایده نخست تنظیم ابرپارامترهای Random Forest با RandomizedSearchCV، تعداد 20 ترکیب و اعتبارسنجی متقاطع 5 بخشی بود. بهترین تنظیم شامل 300 درخت، عمق بیشینه 16، حداقل 4 نمونه در هر برگ، حداقل 2 نمونه برای شکستن گره و max_features=0.5 شد.

ایده دوم ترکیب وزنی سه مدل Random Forest تنظیم شده، XGBoost و Gradient Boosting بود. وزن ها با پیش بینی های خارج از بخش آموزش و با قید نامنفی بودن و مجموع برابر 1 بهینه شدند.

جدول ۱۷: وزن مدل ها در ترکیب بهینه

| Model | Weight |
|---|---|
| Tuned Random Forest | 0.490 |
| XGBoost | 0.000 |
| Gradient Boosting | 0.510 |

جدول ۱۸: مقایسه دو ایده بهبود با مدل پایه

| Method | MAE | RMSE | $R^2$ |
|---|---|---|---|
| Tuned Random Forest | 0.990 | 1.632 | 0.847 |
| Weighted Ensemble | 1.000 | 1.652 | 0.844 |
| Original Random Forest | 0.997 | 1.654 | 0.843 |

تنظیم Random Forest بهترین نتیجه را ایجاد کرد و RMSE را 0.022 واحد کاهش داد. حداقل 4 نمونه در برگ نقش منظم سازی دارد و واریانس مدل را نسبت به جنگل پایه کمتر می کند. ترکیب وزنی نیز اندکی از مدل پایه بهتر است اما

به جنگل تنظیم شده نمی رسد. وزن صفر XGBoost نشان می دهد پیش بینی آن، پس از حضور دو مدل دیگر اطلاعات مکمل کافی برای کاهش خطای خارج از بخش فراهم نکرده است. بهبودها کوچک هستند بنابراین بهتر است در چند تقسیم تکرار و همراه با فاصله اطمینان تایید شوند.

## ۱۰.۴ پرسش دهم

برای تبدیل رگرسیون به طبقه بندی، دانش آموز پرریسک به صورت $G3 < 10$ تعریف شد. در روش مبتنی بر رگرسیون، اگر نمره پیش بینی شده Random Forest تنظیم شده کمتر از 10 بود، نمونه پرریسک در نظر گرفته شد. برای مقایسه، سه طبقه بند مستقیم شامل رگرسیون لجستیک، Random Forest و Histogram Gradient Boosting نیز آموزش داده شدند. معیارهای سطر نخست جدول زیر از آستانه گذاری پیش بینی بهترین مدل پرسش 9 محاسبه شده اند.

جدول ۱۹: مقایسه طبقه بندی مبتنی بر رگرسیون و طبقه بندهای مستقیم

| Method | Accuracy | Balanced accuracy | Precision | Recall | F1 | ROC–AUC |
|---|---|---|---|---|---|---|
| Tuned RF regression + threshold | 0.871 | 0.906 | 0.679 | 0.982 | 0.803 | 0.972 |
| Histogram Gradient Boosting | 0.900 | 0.875 | 0.807 | 0.821 | 0.814 | 0.967 |
| Random Forest Classifier | 0.900 | 0.858 | 0.843 | 0.768 | 0.804 | 0.973 |
| Logistic Regression | 0.871 | 0.872 | 0.710 | 0.875 | 0.784 | 0.959 |

جدول ۲۰: ماتریس درهم ریختگی روشهای طبقه بندی

| Method | TN | FP | FN | TP |
|---|---|---|---|---|
| Tuned RF regression + threshold | 127 | 26 | 1 | 55 |
| Histogram Gradient Boosting | 142 | 11 | 10 | 46 |
| Random Forest Classifier | 145 | 8 | 13 | 43 |
| Logistic Regression | 133 | 20 | 7 | 49 |

روش Histogram Gradient Boosting با $F1 = 0.814$ و دقت 0.9 بهترین تعادل کلی را دارد. در مقابل، آستانه گذاری خروجی رگرسیون با فراخوانی 0.982 فقط یک دانش آموز پرریسک را از دست داده، اما 26 FP ایجاد کرده و دقت مثبت آن به 0.679 کاهش یافته است. بنابراین اگر هزینه از دست دادن دانش آموز پرریسک زیاد باشد، روش رگرسیون و آستانه 10 مناسب تر است. اگر ظرفیت برنامه حمایتی محدود و هزینه FP مهم باشد، طبقه بند Histogram Gradient Boosting انتخاب متعادل تری است. مزیت رگرسیون حفظ نمره پیوسته و امکان تغییر آسان آستانه است مزیت طبقه بند مستقیم نیز بهینه سازی صریح مرز ریسک است.

# ۵ جمع بندی نهایی

نتایج بخش دوم پروژه را میتوان در چند نکته اصلی خلاصه کرد:

۱. در مقایسه چهار روش خوشه بندی با $k = 2$، روش K-Means بهترین رتبه ترکیبی را به دست آورد و دو گروه قابل تفسیر از عملکرد بالاتر و پایین تر ساخت. با این حال، سیلوئت پایین نشان میدهد ساختار خوشه ای داده ضعیف و همپوشان است.

۲. دو معیار انتخاب تعداد خوشه پاسخ یکسانی ندادند. سیلوئت $k = 2$ و شاخص Davies–Bouldin مقدار $k = 6$ را ترجیح داد. انتخاب نهایی باید میان جدایی هندسی، جزئیات و تفسیرپذیری تعادل ایجاد کند.

۳. Random Forest بهترین مدل پایه رگرسیون بود و پس از تنظیم ابرپارامترها به $MAE = 0.990$، $RMSE = 1.632$ و $R^2 = 0.847$ رسید.

۴. نمره G2 با فاصله زیاد مهمترین پیش بین G3 بود. حذف آن و ویژگیهای وابسته، $RMSE$ را $0.6058$ افزایش داد. بنابراین زمان پیش بینی، محدودیت بنیادی دقت را تعیین میکند.

۵. ویژگیهای مشتق شده اثر مثبت اما محدود داشتند، زیرا بیشتر آنها تبدیلهایی از ویژگیهای اصلی هستند و مدلهای درختی بخشی از این رابطه ها را خودشان یاد میگیرند.

۶. خطای مدل در مدرسه MS بیشتر بود. وزن دهی معکوس فراوانی شکافهای خطای درس و مدرسه را کاهش داد، ولی سازش کوچکی با دقت گروههای پرتعداد ایجاد کرد.

۷. در آزمایش نویز، K-Means بیشتر از Random Forest آسیب دید. برش مقاوم توانست بخش عمده کیفیت از دست رفته خوشه بندی را بازیابی کند.

۸. در تبدیل رگرسیون به طبقه بندی، روش آستانه گذاری فراخوانی بسیار بالاتری داشت، در حالی که طبقه بند مستقیم Histogram Gradient Boosting بهترین F1 را ثبت کرد. انتخاب عملی میان این دو به هزینه خطای منفی کاذب و ظرفیت مداخله بستگی دارد.